

Workshop: Explorativní analýza dat (EDA)

Diagnostika datasetu Titanic v Pythonu

Vojtěch Ondryhal

LS 2026

Metodický rámec a struktura workshopu

Cíle:

- Provést komplexní diagnostiku datového souboru před fází čištění a transformace.
- Použít Python Stack s využitím postupů pro efektivní analýzu dat (vektorizace).
- Použít Orange Data Mining pro tvorbu rychlých Workflow s náhledy EDA.

Striktní omezení: V rámci workshopu do dat nezasahujeme (pouze diagnostika).

Fáze analytického procesu

1. Numerická diagnostika (Python)

Implementace analytických úloh 1–5, práce s knihovnami Pandas a Seaborn, technické ladění výpočtů.

2. Vizuální verifikace (Orange)

Paralelní zpracování v grafickém rozhraní Orange, interaktivní průzkum distribucí a korelací.

3. Interpretace a Syntéza

Porovnání výstupů z obou nástrojů, formulace závěrů a dokumentace nálezů v Jupyter Notebooku.

Důraz je kladen na schopnost interpretovat statistické artefakty, nikoliv na pouhou tvorbu grafů.

Dataset Titanic: Specifikace a inicializace

Datový slovník (Klíčové atributy):

- survived: Cílová proměnná (0 = Ne, 1 = Ano).
- pclass: Třída (1 = První, 2 = Druhá, 3 = Třetí).
- sex / age: Pohlaví a věk pasažéra.
- sibsp: Počet sourozenců / manželů na palubě.
- parch: Počet rodičů / dětí na palubě.
- fare: Cena jízdenky (v dobových librách).
- embarked: Přístav nalodění (C, Q, S).
- who / adult_male: Odvozené kategorie.

Načtení a export dat v Pythonu

```
1 import pandas as pd
2 import seaborn as sns
3
4 # Inicializace dat
5 df = sns.load_dataset('titanic')
6
7 # Export pro nástroj Orange Data Mining
8 df.to_csv('titanic_data.csv',
   ↪ index=False)
```

Poznámka k Orange: Vygenerovaný soubor `titanic_data.csv` načtěte pomocí widgetu File. Orange automaticky rozpozná typy proměnných, které jsme identifikovali v EDA.

Úloha 1: Technická inspekce a analýza chybějících dat

Zadání:

1. Načtěte dataset a verifikujte datové typy jednotlivých atributů.
2. Kvantifikujte rozsah chybějících hodnot (*Missing Values*) v absolutních i relativních číslech.
3. Která proměnná je nominální, která ordinální a která poměrová?
4. **Analytická otázka:** U kterého atributu může absence hodnoty indikovat systematickou informaci (MNAR)?

Nápověda

```
1  # Verifikace importu - ukázka dat
2  print(f"Rozměry matice: {df.shape}")
3  display(df.head())
4
5  # Základní přehled a typy
6  print(df.info())
7
8  # Analýza chybějících záznamů
9  print(df.isnull().sum())
10 print(df.isnull().mean() * 100)
```

Úloha 2: Numerická deskripce a detekce odlehlých hodnot

Zadání:

1. Proveďte statistický popis atributu fare. Porovnejte aritmetický průměr a medián.
2. Vypočítejte koeficient šikmosti (*skewness*) pro age a fare. Šikmosti vizualizujte pomocí KDE a interpretujte.
3. Vizualizujte variabilitu fare pomocí Boxplotu segmentovaného dle pclass.
4. **Analytická otázka:** Identifikujte hodnotu, od které lze jízdenku považovat za statistickou anomálii.

Nápověda

```
1  # Statistické momenty
2  print(df['fare'].describe())
3  print(f"Skewness: {df['fare'].skew()}")
4  sns.histplot(df['age'], kde=True)
5
6  # Boxplot pro identifikaci outlierů
7  sns.boxplot(data=df, x='pclass',
   ↪    y='fare')
```

Úloha 3: Studium hustoty pravděpodobnosti a segmentace

Zadání:

1. Vykreslete histogram věku (age) doplněný o odhad hustoty (KDE).
2. Aplikujte segmentaci (*hue*) podle proměnné survived.
3. **Analytická otázka:** Jak se liší věková struktura populace, která katastrofu přežila, oproti celku?
4. Identifikujte lokální maxima (mody) v distribuci.

Nápověda

```
1 import matplotlib.pyplot as plt
2
3 sns.histplot(data=df, x='age', kde=True,
  ↳ hue='survived', element='step',
  ↳ common_norm=False)
```

Úloha 4: Testování asociací kategoriálních proměnných

Zadání:

1. Sestavte kontingenční tabulku frekvencí pro vztah sex a survived.
2. Vizualizujte pomocí skládaného sloupcového grafu.
3. Proveďte χ^2 test nezávislosti pro ověření statistické vazby mezi těmito proměnnými.
4. **Analytická otázka:** Existuje na hladině významnosti $\alpha = 0.05$ dostatek důkazů pro zamítnutí nezávislosti?

Nápověda

```
1 from scipy.stats import chi2_contingency
2
3 ct = pd.crosstab(df['sex'], df['survived'])
4
5 # Skládaný sloupcový graf (Stacked Bar Chart)
6 # normalize=index převede počty na procenta
7 ct_norm = pd.crosstab(df['sex'], df['survived'],
8 ↪ normalize='index')
9 ct_norm.plot(kind='bar', stacked=True)
10
11 stat, p, dof, expected = chi2_contingency(table)
12
13 print(f"p-hodnota testu: {p}")
```

Úloha 5: Multivariační diagnostika a kolinearita

Zadání:

1. Vygenerujte korelační matici pro všechny numerické atributy.
2. Vizualizujte vztahy pomocí Heatmapy a nástroje pairplot.
3. **Analytická otázka:** Které dvojice proměnných vykazují známky redundance (silné lineární závislosti)?

Nápověda

```
1  # Výpočet matice korelací
2  corr = df.select_dtypes('number').corr()
3  sns.heatmap(corr, annot=True,
4  ↪  cmap='coolwarm')
5
6  # Komplexní pohled na vztahy
7  sns.pairplot(df, vars=['age', 'fare',
8  ↪  'pclass'], hue='survived')
```


Metodika odevzdání a struktura výstupu

- **Formát odevzdání:** Soubor Jupyter Notebook (.ipynb).
- **Termín:** Dle instrukcí v IS (standardně do konce cvičení).

Struktura dokumentu (Hierarchie nadpisů)

- # Úloha X: Každá z pěti úloh uvozena nadpisem 1. úrovně.
- ## Python Stack: Implementace v kódu, vizualizace (Seaborn/Matplotlib).
- ## Orange Data Mining: Snímky vytvořeného workflow a výstupních oken (grafy, statistiky).

Požadavky na textovou interpretaci

- **Závěr k části úlohy:** Interpretace výsledků v rámci úlohy pro Python i Orange.
- **Závěr úlohy:** Syntéza nálezů za celou kapitolu dle analytických otázek.
- **Shrnutí:** Finální porovnání přístupů (výhody/limity Pythonu vs. Orange pro daný typ analýzy).

Kvalita slovní interpretace statistických jevů má vyšší váhu než samotný kód.