

Architektura a metodologie datové vědy

Snížení informační entropie prostřednictvím analytických modelů

Vojtěch Ondryhal

K209, FVT, UO

LS 2026, Analýza informačních zdrojů

Současná paradigmata ukládání dat (distribuované systémy, cloud) vedou k vysoké míře **datové heterogenity**.

- **Limitace tradičních přístupů:** Pasivní SQL dotazy nestačí na extrakci znalostí z nestrukturovaných zdrojů.
- **Latentní vzory:** Nutnost identifikovat skryté struktury, které nejsou zjevné na první pohled.
- **Metodický rámec:** Data Science není jen evolucí Data Miningu, ale komplexním procesem transformace vstupů na strategické znalosti.

Definice cíle

Transformace surových, nestrukturovaných vstupů na **akceschopné znalosti** a podporu rozhodování.


Data Science jako nástroj snižování entropie

Informační entropie

- Míra neurčitosti, neuspořádanosti nebo „překvapení“ v datech.
- Surová data = **Vysoká entropie** (vysoký šum, neznámé vazby).

Role analytického modelu

1. **Filtrace:** Oddělení signálu od šumu.
2. **Kompresa:** Nahrazení milionů transakcí parametry funkce.
3. **Predikce:** Zvýšení jistoty o budoucím stavu.



Datový vědec je inženýrem řádu, který transformuje chaos na hodnotu.


Co je (vlastně) Datová věda?

Datová věda není izolovaná disciplína, ale **interdisciplinární průnik**:

- **Matematika a statistika:** Teoretický aparát, modely, pravděpodobnost.
- **Informatika:** Algoritmy, škálování, čištění dat, programování.
- **Doménová znalost:** Schopnost položit správnou otázku a interpretovat výsledek.

Cíl: Extrakce znalostí z dat pro podporu rozhodování.

Vennův diagram DS



Data Science vs. Business Intelligence (BI)

Vlastnost	Business Intelligence	Data Science
Orientace	Retrospektivní (Minulost)	Prospektivní (Budoucnost)
Otázka	"Co se stalo?"	"Co se stane? Proč?"
Data	Strukturovaná (SQL, ERP)	Všechny typy (Text, Video, Logy)
Analýza	Deskriptivní (Reporty)	Prediktivní (Modely)

Krise intuice: Proč potřebujeme vědecký přístup?

- Lidský mozek je evolučně nastaven na **rychlé vzorce** (heuristiky). Rychlost před přesností.
- **Data Science jako ochrana:** Metody, které nás chrání před naším vlastním chybným úsudkem.
- Věda (včetně té datové) neexistuje proto, aby potvrzovala naše domněnky, ale aby je nemilosrdně testovala.

"The great tragedy of Science — the slaying of a beautiful hypothesis by an ugly fact."

Thomas Henry Huxley, britský biolog

"Intuice je dobrá pro tvorbu hypotéz, data pro jejich popravu."

Evoluční kořeny: Rychlost nad přesností

V savaně nebylo cílem najít globální minimum chybové funkce, ale **přežít příštích 5 sekund**.

- **Heuristika:** Mentální zkratka. Mozek ignoruje část informací pro okamžité rozhodnutí.
- **Příklad (Šustění v trávě):**
 - *Analytický přístup:* "Existuje 5% pravděpodobnost lva. Potřebuji víc dat..." → **Analytik je sežrán.**
 - *Heuristický přístup:* "Šustění = Nebezpečí = Uteč!" → **Přeživší předává geny.**
- **Závěr:** Evoluce nás optimalizovala na **minimalizaci falešně negativních výsledků** (přehlédnutí lva) i za cenu mnoha **falešně pozitivních** (útěk před větrem).

Kognitivní zkreslení (Biases) v moderním světě

Heuristiky vedou k **kognitivním zkreslením**. Zkratky, které nás zachránily v přírodě, nás v analýze dat klamou:

- **Patternicity (Hledání vzorců):** Mozek nenávidí náhodnost. Vidíme obličeje v mracích i trendy v náhodném šumu akciového trhu.
- **Confirmation Bias (Potvrzovací zkreslení):** Všímáme si dat, která potvrzují náš názor, a ignorujeme ta ostatní. (Antiteze k "popravě hypotéz").
- **Availability Heuristic (Heuristika dostupnosti):** Považujeme za pravděpodobnější to, co si snadno vybavíme (např. pád letadla), i když je to statisticky extrémně vzácné.

2 systémy myšlení (Daniel Kahneman)

Nobelova cena za ekonomii (2002) za popis dvou režimů myšlení:

Systém 1 (Rychlý)

- Intuitivní, emoční.
- Založený na heuristikách.
- "Evoluční mozek".
- *Staví hypotézy.*



Systém 2 (Pomalý)

- Racionální, logický.
- Výpočetně náročný.
- **Datová věda.**
- *Prověřuje hypotézy.*



"Práce datového vědce je vědomé přepnutí do Systému 2."

Proč tradiční intuice selhává právě dnes? Protože objem a komplexita informací přesáhly kapacitu lidského mozku. **Charakteristika 3V (původní model):**

- **Volume (Objem):** Terabyty až petabyty dat. Už se nevejdou do paměti jednoho počítače.
- **Velocity (Rychlost):** Data vznikají v reálném čase (senzory, sociální sítě, burza).
- **Variety (Rozmanitost):** Text, video, GPS souřadnice, logy. Nejen tabulky.

Dvě klíčová "V" pro datového vědce:

- **Veracity (Věrohodnost):** Data jsou špinavá, neúplná a klamavá.
- **Value (Hodnota):** Data jsou surovina, kterou musíme rafinovat na znalost.

Big Data jsou prostředím, kde se naše evoluční zkratky (heuristiky) stávají nebezpečnými.

Případová studie I: Abraham Wald (1943)

Problém: Kam přidat pancíř na bombardéry B-17?

- **Pozorování (Data):** Letadla, která se vrátila, mají díry v trupu a křídlech.
- **Intuitivní závěr:** Pancéřovat trup a křídla (tam jsou přece díry!).

Případová studie I: Abraham Wald (1943)

Problém: Kam přidat pancíř na bombardéry B-17?

- **Pozorování (Data):** Letadla, která se vrátila, mají díry v trupu a křídlech.
- **Intuitivní závěr:** Pancéřovat trup a křídla (tam jsou přece díry!).
- **Waldův závěr:** Pancéřovat **motory a kokpit**.

Klam přeživších (Survivorship Bias): Vzorek je zkreslený – analyzujeme pouze ty, kteří přežili. Zásah do motoru znamenal pád (absence dat v datasetu).

Případová studie II: Simpsonův paradox

Definice: Jev, kdy trend patrný v jednotlivých skupinách dat zmizí nebo se **obráť** poté, co jsou tyto skupiny sloučeny.

Příklad: Která nemocnice je úspěšnější v léčbě?

Nemocnice	Celková úspěšnost	Data
Nemocnice A	78 %	(273 / 350)
Nemocnice B	83 %	(289 / 350)

Případová studie II: Simpsonův paradox

Definice: Jev, kdy trend patrný v jednotlivých skupinách dat zmizí nebo se **obráť** poté, co jsou tyto skupiny sloučeny.

Příklad: Která nemocnice je úspěšnější v léčbě?

Nemocnice	Celková úspěšnost	Data
Nemocnice A	78 %	(273 / 350)
Nemocnice B	83 %	(289 / 350)

Intuice říká: "Běžte do Nemocnice B."

Simpsonův paradox: Rozklad podle náročnosti

Podívejme se na úspěšnost podle velikosti ledvinových kamenů (náročnost):

Typ případu	Nemocnice A	Nemocnice B	Vítěz
Malé kameny (lehké)	93 % (81/87)	87 % (234/270)	Nem. A
Velké kameny (těžké)	73 % (192/263)	69 % (55/80)	Nem. A
CELKEM (Agregát)	78 %	83 %	Nem. B??

Simpsonův paradox: Rozklad podle náročnosti

Podívejme se na úspěšnost podle velikosti ledvinových kamenů (náročnost):

Typ případu	Nemocnice A	Nemocnice B	Vítěz
Malé kameny (lehké)	93 % (81/87)	87 % (234/270)	Nem. A
Velké kameny (těžké)	73 % (192/263)	69 % (55/80)	Nem. A
CELKEM (Agregát)	78 %	83 %	Nem. B??

Proč se to děje? (Skrytá proměnná / Confounder)

- Nemocnice A je specializované centrum → bere **75 % nejtěžších případů**.
- Nemocnice B je lokální klinika → **77 % jejích pacientů jsou lehké případy**.
- Celkový průměr Nemocnice A je "stahován dolů" náročností její práce.

Ponaučení: Agregace je nebezpečná

- **Data bez kontextu lžou:** Průměr může maskovat realitu v podskupinách.
- **Role Datového vědce:** Musí identifikovat "rušivé proměnné" (*confounders*), které zkreslují výsledek.
- **Cesta ven:** Segmentace dat a hloubková analýza (EDA).

"Nikdy nedělejte rozhodnutí na základě jediného agregovaného čísla, aniž byste znali distribuci pod ním."

1. **Data bez kontextu jsou nebezpečná.**
2. **Analýza chybějících dat** je stejně důležitá jako analýza těch přítomných.
3. **Generativní proces:** Než začnete modelovat, musíte pochopit, jak data vznikla.

Výběr metody závisí na tom, **jakou informaci** máme v datech k dispozici:

1. Učení s učitelem (Supervised Learning):

- Máme k dispozici "správné odpovědi" (labels).
- Cíl: Najít funkci $f : X \rightarrow y$.

2. Učení bez učitele (Unsupervised Learning):

- Máme pouze data X , bez labelů.
- Cíl: Najít skrytou strukturu nebo vzorce.

3. Zpětnovazebné učení (Reinforcement Learning):

- Agent se učí pokusem a omylem v prostředí.
- Cíl: Maximalizace odměny (reward).

Taxonomie strojového učení

Supervised Learning: Regrese vs. Klasifikace

Nejčastější úlohy v praxi – dělíme je podle typu výstupu y :

Regrese (Spojitý výstup)

- Předpovídáme číslo.
- Příklad: Cena nemovitosti, teplota zítra, výše úvěru.
- Metrika: MSE, MAE.

Klasifikace (Diskrétní výstup)

- Předpovídáme kategorii (třídu).
- Příklad: Spam/Ham, diagnóza, rozpoznání číslice.
- Metrika: Accuracy, F1-score.

Taxonomie strojového učení


Unsupervised Learning: Hledání řádu v chaosu

Pracujeme s daty bez "správných odpovědí". Cílem je odhalit skrytou vnitřní strukturu:


- **Clustering (Shlukování):** Seskupování podobných objektů.
 - *Příklad:* Segmentace zákazníků podle nákupního chování.
- **Asociační pravidla (Market Basket Analysis):** Hledání vztahů mezi položkami v transakcích.
 - *Příklad:* "Lidé, kteří koupili X, často kupují i Y." (Doporučovací systémy).
 - Klíčové metriky: Support, Confidence, Lift.
- **Anomálie (Outliers):** Identifikace bodů, které neodpovídají běžnému vzorci.
 - *Příklad:* Detekce podvodných transakcí na kreditní kartě.
- **Redukce dimenzionality:** Zjednodušení komplexních dat (např. PCA).

Taxonomie strojového učení


Vizuální přehled úloh strojového učení



Regrese (spojitá)



Klasifikace (diskrétní)



Clustering (shluky)

Košík 1: {Pivo, Chipsy}

Košík 2: {Pivo, Chipsy, ...}

Pravidlo:

Pivo $\rightarrow$ Chipsy

Asociace (vztahy)

Taxonomie strojového učení

Pohled roku 2026: Nad rámec základů

Tradiční rozdělení se dnes stírá díky moderním architekturám:

- **Self-supervised Learning:** Model se učí z dat samotných (maskování slov v textu). Základ všech LLM (GPT, Claude).
- **Semi-supervised:** Máme málo labelů, ale miliony neoznačených příkladů.
- **Transfer Learning:** Vezmeme model naučený na milionech obrázků a "doladíme" ho pro náš specifický problém (např. rentgeny plic).

Typologie dat

Od tabulek k hlubokému učení

Výběr metody (Supervised/Unsupervised) přímo závisí na tom, jaký typ dat máme v ruce:

- **Strukturovaná data (20 % objemu):**

- Tabulky, SQL databáze, CSV.
- Každý sloupec má jasný typ (číslo, datum, text).
- **Nástroje:** Specializované knihovny pro "tabulkovou" manipulaci (*DataFrames*).
- **Polars / Pandas** – software, který se naučíme ovládat pro čištění a analýzu těchto tabulek.

- **Nestrukturovaná data (80 % objemu):**

- Textové dokumenty, audio, video, obrázky.
- **Klíčová výzva:** Jak z obrázku nebo textu udělat číselný vektor?
- **Nástroje:** Deep Learning modely (PyTorch, TensorFlow) a moderní LLM.

"Cílem Data Science je transformovat nestrukturovaný svět do číselných matic (X), kterým rozumí algoritmy."

Typologie dat

Statistické typy proměnných

Než začnete kreslit grafy (EDA), musíte vědět, co máte v ruce:

Typ	Vlastnost	Příklad
Nominální	Kategorie bez pořadí	Barva, Pohlaví, OS
Ordinální	Kategorie s pořadím	Hodnocení (1–5), Vzdělání
Intervalová	Číselná (lze sčítat)	Teplota v °C, Datum
Poměrová	Má absolutní nulu	Cena, Hmotnost, Počet

Proč na tom záleží? Na nominální data nemůžete pustit průměr!


Zapomeňme na lineární postup. DS je **iterativní cyklus** (moderní OSEMN):

1. **Obtain**: Získání dat (SQL, API, Scraping).
2. **Scrub**: Čištění a transformace.
3. **Explore**: Explorační analýza (EDA). *Tady vznikají vhledy.*
4. **Model**: Strojové učení a statistické modelování.
5. **INterpret**: Interpretace a komunikace výsledků.

Zlaté pravidlo: 80 % času strávíte v krocích O a S. Modelování je jen třešnička na dortu.

Metodika OSEMN

Realita iteračního procesu



Životní cyklus projektu

Proč projekty selhávají?

- **Špatná otázka:** Máme skvělý model na problém, který nikoho nezajímá.
- **GIGO (Garbage In, Garbage Out):** Model trénovaný na nekvalitních datech.
- **Nedostatek doménové znalosti:** Interpretace korelace jako kauzality (viz Simpsonův paradox).
- **Technický dluh:** Neschopnost nasadit model do produkce (MLOps).

- Datová věda je **inženýrská disciplína** postavená na matematických základech.
- Naše intuice je nespolehlivá – věříme datům, ale prověřujeme jejich původ.
- Cvičení: Instalace prostředí

Příště: Explorační analýza dat (EDA) – jak se nenechat obelhat.