

Průzkumová analýza dat

Statistické uvažování a vnímání distribucí

Vojtěch Ondryhal

K209, FVT, UO

LS 2026, Analýza informačních zdrojů

- 1 Průzkumová analýza dat
- 2 Analýza jedné proměnné
 - Kvantilové charakteristiky a Boxplot
 - Centrální momenty
 - Klíčové typy rozdělení v praxi
- 3 Analýza dvou proměnných
 - Pearsonův koeficient
 - Spearmanův koeficient
 - Kontingenční tabulka
- 4 Analýza více proměnných

Průzkumová analýza dat

Průzkumová analýza dat (EDA)

Definice (Exploratory Data Analysis)

Statistický přístup k analýze datových souborů za účelem **extrakce hlavních charakteristik** a **identifikace vnitřní struktury** pomocí analytických a vizualizačních metod.

- **Cíl:** Porozumět struktuře dat dříve, než začneme tvořit prediktivní modely.
- **Kognitivní limit:** Surová data ($n \times p$ matice) neumožňují efektivní posouzení vícerozměrných vztahů a lokálních hustot pravděpodobnosti bez agregace či transformace.

Základní analytické otázky EDA

1. **Centrální tendence:** Jaké jsou typické hodnoty?
2. **Variabilita:** Jaká je disperze a rozsah hodnot?
3. **Anomálie:** Jsou v datech přítomny odlehlá pozorování (outliers)?
4. **Asociace:** Jaké jsou korelační vztahy mezi proměnnými?

Data = Signál + Šum

- **Základní axiom modelování:** Každé pozorování v datech se skládá ze dvou složek.

Signál (Informace)

- Ta část dat, která má **strukturu**.
- Je deterministická a opakovatelná.
- Reprezentuje vztahy, které chceme modelem zachytit ($f(x)$).
- *Příklad: Trend růstu cen nemovitostí.*

Šum (Náhodnost)

- Náhodné variace a chyby měření.
- Nemá žádný vnitřní význam ani vzorec.
- Pokud ho modelujeme, dochází k **přeučení** (overfitting).
- *Příklad: Zaokrouhlovací chyby, náhodné výkyvy trhu.*

- **Role EDA:** Pomocí statistických metod a vizualizace "odfiltrovat" šum a identifikovat charakteristiku signálu.

Formálně lze zapsat: $Y = f(X) + \varepsilon$, kde ε je šum.

Detekce anomálií: Outlier vs. Vlivný bod

- V rámci EDA nehledáme jen chyby, ale studujeme **vzdálenost a páku** bodů.

Outlier (Odlehlé pozorování)

- Bod s extrémní hodnotou v Y (vysoké reziduum).
- **Dopad:** Zvyšuje variabilitu šumu (σ^2), ale obvykle zásadně nemění trend $f(X)$.

Vlivné pozorování

- Bod s extrémní hodnotou v X (vysoká páka / leverage).
- **Dopad:** Má sílu "přitáhnout" model k sobě a zcela **zkreslit parametry** signálu.

Proč to řešíme v EDA?


Cílem je rozhodnout, zda je anomálie **chyba měření** (stochastický šum ε) nebo **vzácný jev**, který vyžaduje změnu struktury modelu $f(X)$.

Vizuální diagnostika: Outlier vs. Vlivný bod

- **Outlier (Červená):** Výrazná vertikální odchylka od modelu. Zvyšuje průměrnou chybu, ale obvykle nemění sklon.
- **Vlivný bod (Oranžová):** Má vysokou "páku" díky extrémní hodnotě X . I malá chyba v Y u tohoto bodu dramaticky vyosí celou regresní funkci.

EDA Insight

Grafické posouzení reziduí je často efektivnější než prosté sledování korelačního koeficientu r .



Typologie proměnných

Kategoriální (Kvalitativní)

- **Nominální:** Identifikátory bez vnitřního uspořádání (např. barva, krevní skupina, ID).
- **Ordinální:** Hodnoty se srozumitelným pořadím, ale nejasnou vzdáleností (např. úroveň vzdělání, Likertova škála).

Numerické (Kvantitativní)

- **Intervalové:** Rozdíl mezi hodnotami je konstantní, ale nula je relativní (např. teplota v °C).
- **Poměrové:** Existuje absolutní nula (nulové množství). Lze počítat podíly (např. příjem, délka, hmotnost).

Data Engineering: Transformace

Encoding: Převod kategorií na číselné vektory (*One-Hot Encoding* pro nominální, *Label Encoding* pro ordinální data). [w-eda-encoding.ipynb](#)

Binning: Diskretizace spojité proměnné do kategoriálních intervalů (např. spojitý věk → generace). [w-eda-binning.ipynb](#)


Poznámka: Typ proměnné určuje výběr statistického testu i vizualizační metody.

Struktura dat: Datová matice (Design Matrix)

- Základní formát pro statistické učení je matice $\mathbf{X}$ typu $n \times p$.

Anatomie datové množiny

- **Objekt (i -tý řádek):** Instance, záznam nebo **vlastnosti (feature vector)** $\mathbf{x}_i$. Reprezentuje jednu entitu.
- **Atribut (j -tý sloupec):** Proměnná, příznak nebo **dimenze**. Reprezentuje měřenou charakteristiku.
- **Hodnota (x_{ij}):** Konkrétní realizace j -tého příznaku pro i -tý objekt.



- **Tidy Data:** Standard, kde každá proměnná tvoří sloupec, každé pozorování řádek a každý typ observační jednotky tabulku.

Analýza jedné proměnné

Jednorozměrná analýza: Kategoriální proměnná

- U diskrétních dat sledujeme strukturu četností jednotlivých kategorií.

Deskriptivní statistika

- **Absolutní četnost** (n_i): Počet výskytů.
- **Relativní četnost** (f_i): Podíl na celku (n_i/n).
- **Modus** ($\hat{x}$): Kategorie s nejvyšší četností (nejčastější profil).

Vizualizace

- **Bar Chart**: Výška sloupce $\propto$ četnost. Mezi sloupci jsou mezery (diskretizace).
- **Pie Chart**: Pro proporce k celku. *Kognitivní limit*: Lidské oko hůře porovnává úhly než délky.

Pozor na záměnu!

Bar Chart zobrazuje nespojité kategorie. **Histogram** zobrazuje spojitá data rozdělená do intervalů (bins).

Jednorozměrná analýza: Spojitá proměnná

- **Cíl:** Pochopit, jak jsou hodnoty jedné proměnné rozprostřeny v prostoru.

Histogram

- Ukazuje frekvenci hodnot v intervalech (bins).
- **Sledujeme:** Modalitu (počet vrcholů), šikmost (asymetrii) a špičatost.
- *Citlivost na volbu šířky intervalu!*

Kernel Density Estimation (KDE)

- Spojitý odhad hustoty pravděpodobnosti.
- Vyhlazená verze histogramu, která eliminuje vliv hranic intervalů.

`w-eda-kde.ipynb`

Klíčová otázka


Odpovídají data Normálnímu (Gaussovu) rozdělení? Mnoho statistických testů a modelů (např. lineární regrese) tento předpoklad vyžaduje.

Vizualizace distribuce: Histogram a volba „Binů“

- Histogram je základní nástroj pro zobrazení hustoty dat, ale jeho výpovědní hodnota závisí na šířce intervalů (bins).
- **Příliš široké biny:** Vedou k nadměrnému vyhlazení a ztrátě jemné struktury (např. bimodality).
- **Příliš úzké biny:** Zobrazují šum v datech místo skutečného trendu.

Pravidla pro volbu k (počet binů)

- **Sturgesovo pravidlo:** $k = 1 + \log_2(n)$
- **Freedman-Diaconis:** Bere v úvahu rozptyl (IQR).



`w-eda-histogram.ipynb`

Centrální tendence a vliv outlierů

- **Příklad:** 10 lidí v baru s příjmem 30 000 Kč.

Aritmetický průměr ($\bar{x}$)

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- **Citlivost:** Extrémně ovlivněn odlehlými hodnotami.

Medián ($\tilde{x}$)

- **Robustnost:** Prostřední hodnota seřazené řady.

Robustní statistiky v EDA

- **Trimmed Mean:** Odstranění $p\%$ extrémů před výpočtem průměru.
- **Winsorized Mean:** Nahrazení extrémů mezními hodnotami intervalu.

Centrální tendence a vliv outlierů

- **Příklad:** 10 lidí v baru s příjmem 30 000 Kč. **Přijde Bill Gates :).**

Aritmetický průměr ($\bar{x}$)

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- **Citlivost:** Extrémně ovlivněn odlehlými hodnotami.
- **Výsledek:** Průměrný příjem v baru se zvedne na miliony.

Medián ($\tilde{x}$)

- **Robustnost:** Prostřední hodnota seřazené řady.
- **Výsledek:** Hodnota zůstává na 30 k Kč. Miliardář ji téměř neovlivní.
- `w-eda-centralni-tendence.ipynb`

Robustní statistiky v EDA

- **Trimmed Mean:** Odstranění $p\%$ extrémů před výpočtem průměru.
- **Winsorized Mean:** Nahrazení extrémů mezními hodnotami intervalu.

Variabilita: Rozptýlení informace

- Dva systémy mohou mít stejný průměr, ale diametrálně odlišnou spolehlivost.


Statistické momenty

- **Rozptyl (σ^2):** Průměrná čtvercová vzdálenost od průměru.
- **Směrodatná odchylka (σ):** Odmocnina z rozptylu (v jednotkách dat).

Pravidlo 3σ (Empirické pravidlo)

V normálním rozdělení $\mathcal{N}(\mu, \sigma^2)$ platí:

- **68,2 %** dat leží v rozsahu $\mu \pm 1\sigma$.
- **95,4 %** dat leží v rozsahu $\mu \pm 2\sigma$.
- **99,7 %** dat leží v rozsahu $\mu \pm 3\sigma$.



Vše mimo 3σ je v EDA považováno za

kandidáta na anomálii.

`w-eda-variabilita.ipynb`

Kvantily: Jak rozdělit data na části?

Definice kvantilu

Kvantil Q_p je hodnota, pod kterou leží $p \times 100\%$ všech pozorování.

- **Medián** ($Q_{0.50}$): Rozděluje data na dvě stejné poloviny.
- **Kvartily** ($Q_{0.25}, Q_{0.75}$): Rozdělují data na čtvrtiny.
- **Decily** ($Q_{0.1}, Q_{0.9}$): Rozdělují data na desetiny.
- **Percentily** ($Q_{0.01} \dots Q_{0.99}$): Rozdělují data na setiny (např. v testech IQ nebo růstových grafech).

Kvartilové rozpětí (IQR)

$$IQR = Q_3 - Q_1$$

- Reprezentuje šířku "prostředních" 50 % dat.
- Na rozdíl od rozptylu (variance) je **robustní** vůči odlehlým hodnotám.

Proč je používáme?

- Popisují **polohu** a **variabilitu** bez ohledu na to, zda jsou data "hezky" symetrická (normální rozdělení).
- Jsou základem pro detekci extrémů.

Percentily v praxi: Od školství po IT systémy

1. Standardizované testy (SAT / Scio)

- *Interpretace:* Výsledek není o počtu bodů, ale o postavení v populaci.
- *Příklad:* 90. percentil znamená: „Byli jste lepší než 90 % ostatních uchazečů.“
- **Význam:** Umožňuje srovnatelnost výsledků i u různě těžkých variant testů v čase.

2. Marketingová segmentace (RFM)

- *Metoda:* Rozdělení zákazníků podle *Recency* (kdy), *Frequency* (často) a *Monetary* (útrata).
- *Příklad:* Horní **decil (top 10 %)** podle útraty generuje většinu zisku.
- **Význam:** Efektivní cílení slev a kampaní jen na relevantní skupiny.

3. Kvalita IT služeb (SLA)

- *SLA (Service Level Agreement):* Smluvní záruka kvality odezvy systému.
- *Příklad:* Sleduje se **P99** (99. percentil) latence. Musí být např. pod 500 ms.
- **Význam:** Průměr lže. P99 odhalí, zda se systém nezasekává pro menšinu uživatelů.

4. Měření nerovnosti (P90/P10)

- *Metrika:* Poměr mezi 9. a 1. decilem v distribuci příjmů domácností.
- *Příklad:* Kolikrát více vydělává „bohatých top 10 %“ oproti „chudým spodním 10 %“.
- **Význam:** Mnohem přesnější ukazatel sociální stability než průměrná mzda.

w-eda-kvantily.ipynb

Vizuální diagnostika: Boxplot


Boxplot

"Rentgenový snímek" distribuce, který odhaluje asymetrii.

- **Medián (Q_2):** Čára uprostřed boxu.
- **Box (IQR):** $Q_3 - Q_1$. Obsahuje 50 % hodnot.
- **Meze (Whiskers):** $1.5 \times IQR$ od hran boxu.
- **Tečky (Outliers):** Body mimo tyto meze.

Výhoda pro EDA

Na rozdíl od průměru a σ vidíme polohu mediánu vůči kvartilům (šikmost) a identifikujeme konkrétní extrémní najednou.



`w-eda-titanic-live.ipynb`

(Seznámení s titanic + Blok 2).

Vyšší statistické momenty: Architektura distribuce

- Geometrii dat popisujeme pomocí hierarchie **standardizovaných momentů**.
- Každý vyšší moment zvyšuje citlivost modelu na odlehlé hodnoty.

Hierarchie popisu dat

1. **Průměr** (μ): Těžiště a poloha.
2. **Rozptyl** (σ^2): Měřítko a variabilita.
3. **Šikmost** (γ_1): Směr a míra asymetrie.
4. **Špičatost** (γ_2): Síla chvostů (riziko extrémů).

Logika umocňování

Všimněte si exponentů ve vzorcích:

- **2. mocnina:** Odstraňuje znaménko.
- **3. mocnina:** Zachovává směr výchyly.
- **4. mocnina:** Extrémně zesiluje váhu odlehlých bodů.

- **Cíl EDA:** Identifikovat, zda se data chovají "normálně", nebo zda v nich číhají strukturální rizika (tzv. Černé labutě).

Kvantifikace nejistoty: Rozptyl a odchylka

- Samotný průměr nestačí – musíme vědět, jak moc mu můžeme věřit.

Rozptyl (Variance) σ^2

Průměrná čtvercová odchylka od průměru:

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

- **Proč kvadrát?:** Aby se kladné a záporné odchylky nevyrušily + penalizace velké chyby.
- **Nevýhoda:** Jednotky jsou „na druhou“ (např. Kč²), což ztěžuje přímou interpretaci.

Směrodatná odchylka σ

Odmocnina z rozptylu:

$$\sigma = \sqrt{\sigma^2}$$

- Má stejné jednotky jako původní data.
- Základní měřítko „chyby“ nebo „rizika“ v daném kontextu.

EDA Insight

Pokud je σ v poměru k průměru $\bar{x}$ příliš vysoká, průměrná hodnota není reprezentativní a v datech dominuje šum.

Asymetrie dat: Šikmost (Skewness)


- Měří jednostranné vybočení distribuce vůči průměru.

Matematický aparát

Definována jako 3. standardizovaný moment:

$$\gamma_1 = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{\sigma} \right)^3$$

- $\gamma_1 > 0$: Dlouhý **pravý** chvost (příjmy).
- $\gamma_1 < 0$: Dlouhý **levý** chvost (věk při úmrtí).



Pokud $Mean \gg Median$, data jsou silně šikmá a průměr je zavádějící.

Když vidíte vysokou šikmost nebo špičatost, lineární modely (jako lineární regrese) budou pravděpodobně fungovat špatně, protože se snaží minimalizovat čtverce chyb, a tyhle 'ocasy' jim úplně rozhodí výpočet.

Koncentrace v chvostech: Špičatost (Kurtosis)


- Popisuje nahuštění dat u středu a pravděpodobnost extrémních hodnot.

Koeficient špičatosti

Definována jako 4. standardizovaný moment:

$$\gamma_2 = \left[\frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{\sigma} \right)^4 \right] - 3$$

- $\gamma_2 = 0$: Je to „normální“ (Gaussové).
- $\gamma_2 > 0$: **Špičatější** než Gaussovo (nebezpečné chvosty).
- $\gamma_2 < 0$: **Plošší** než Gaussovo (bezpečné, předvídatelné).



Black Swan Alert

Kladná špičatost znamená, že extrémní výkyvy jsou pravděpodobnější, než by odpovídalo Gaussově křivce.


[w-eda-centralni-momenty.ipynb](#)

Klíčové typy rozdělení v praxi

- Ne všechna data v reálném světě následují symetrické Gaussovo rozdělení.

Klíčové distribuční modely

- **Gaussovo (Normální):** Symetrické, zvon.
Příklad: Výška populace, chyby měření.
- **Log-normální (Fat tails):** Dlouhý pravý chvost.
Příklad: Bohatství, velikost měst.
- **Bimodální:** Dvě lokální maxima (hrby).
Příklad: Výška ($M+\check{Z}$), věk ($J+S$).



EDA Insight: Bimodální data

Signalizuje, že soubor obsahuje dvě vnitřně odlišné populace.

Úloha k zamyšlení

Jaké rozdělení byste čekali u těchto veličin?

- "**Čas strávený na webu**" (bounce rate vs. power users).
- "**Velikost bot**" (pokud smícháme všechna pohlaví v datech).

Interpretace distribucí: Praktické dopady

Úloha k zamyšlení

Jaké rozdělení byste čekali u těchto veličin?

- **"Čas strávený na webu"** (bounce rate vs. power users).
- **"Velikost bot"** (pokud smícháme všechna pohlaví v datech).

Čas na webu & Peníze

Log-normální distribuce

- Většina uživatelů odejde hned, pár jich zůstane hodiny.
- Průměrný čas nereprezentuje nikoho.
- **Sledujte medián!**

Velikost bot

Bimodální distribuce

- Pokud smícháte muže a ženy, průměr (např. 40) nikomu nesedí, leží v „údolí“.
- **Segmentujte data!**

`w-eda-distribuce.ipynb`

Závěr: *Před výpočtem průměru se vždy podívejte na histogram!*


Analýza dvou proměnných

Bivariační analýza: Hledání souvislostí

- Přecházíme od popisu jedné proměnné ke zkoumání **interakcí**.

Scatter Plot (Bodový graf)

- Základní nástroj pro vizualizaci vztahu dvou numerických proměnných.
- **Co v něm hledáme?**
 - Trend (Lineární vs. Nelineární).
 - Shluky (Clusters).
 - Heteroskedasticitu (proměnlivý rozptyl).



Pozitivní korelace: Hodnoty se pohybují společně.

Zlaté pravidlo EDA

Correlation $\neq$ Causality! Skutečnost, že se dvě proměnné pohybují společně, neznamená, že jedna způsobuje druhou (problém "třetí proměnné").

Anscombeův kvartet: Čísla nejsou všechno


Identické statistiky pro 4 sady:

- Průměr $x = 9.0$, průměr $y = 7.5$
- Korelace $r = 0.816$
- Lineární regrese: $y = 3 + 0.5x$

Ponaučení

Slepá důvěra v agregované ukazatele bez vizuální kontroly vede k chybným závěrům.

`w-eda-ascombe.ipynb`



Analýza lineární závislosti: Pearsonův koeficient (r)


Definice a vzorec

Kvantifikuje sílu a směr **lineárního** vztahu mezi proměnnými.

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

Interpretace a předpoklady:

- **Rozsah:** $[-1, 1]$. 0 = absence lineárního vztahu.
- **Data:** Spojitá, normálně rozdělená.
- Konstantní rozptyl podél trendu.



Lineární trend ($r \approx 0.95$)

*Před výpočtem r vždy zkontrolujte
Scatter Plot!*

Kritické omezení

Extrémní citlivost na **odlehlé hodnoty**. Jeden outlier může r dramaticky změnit.


Limity korelace: Nelinearita a Kauzalita

Slepá místa Pearsonova r

- **Nelineární vztahy:** U symetrických funkcí (např. $y = x^2$) vychází $r \approx 0$ i při jasné závislosti.
- **Korelace $\neq$ Kauzalita:** Statistická asociace neimplikuje příčinný vztah.

Robustní řešení: Spearmanovo ρ

- Založeno na **pořadí** (Ranks).
- Odolné vůči outlierům.
- Zachytí nelineární **monotonní** trendy.



Zlaté pravidlo EDA

Nízká korelace není důkazem nezávislosti.
Vizuální diagnostika je nezbytná.

Robustní korelace: Spearmanův koeficient (ρ)

Definice


Jde o Pearsonovo r vypočítané z **pořadí** (Ranks) původních hodnot X a Y .

Spearmanův koeficient nezkoumá absolutní vzdálenosti mezi body, jen jejich **hierarchii** (pořadí).

Princip transformace na pořadí:

- Původní: $X = \{1, 2, 100\}$, $Y = \{10, 20, 1000\}$
- Pořadí: $R(X) = \{1, 2, 3\}$, $R(Y) = \{1, 2, 3\}$
- **Výsledek:** Dokonalá shoda ($\rho = 1.0$), přestože vztah není lineární.
- **Robustnost:** Hodnota 1 000 má stejný vliv jako 10, pokud jsou obě nejvyšší v souboru.

Doporučení: Vždy počítejte obě hodnoty. Pokud se výrazně liší, v datech jsou outliers nebo nelineární trend.



Monotonní trend: $r < 1$ ale $\rho = 1$

Kdy volit Spearmana?

- Přítomnost **odlehklých hodnot**.
- Nelineární, ale **monotonní** vztahy.
- Ordinální data (nappř. Likertova dotazníková škála 1 – 5).

`w-eda-korelace.ipynb`

Vztahy mezi kategoriemi: Kontingenční tabulka

Kontingenční tabulka (Crosstab)

Matice četností kombinací dvou proměnných.

- **Absolutní:** Počty výskytů.
- **Relativní:** Procentuální podíly v řádcích/sloupcích.

Pozorované (observed) četnosti

	y_1	y_2	$\dots$	y_c	
x_1	O_{11}	O_{21}	$\dots$	O_{1c}	O_{x_1}
x_2	O_{11}	O_{22}	$\dots$	O_{2c}	O_{x_2}
$\dots$	$\dots$	$\dots$	$\dots$	$\dots$	
x_r	O_{r1}	O_{r2}	$\dots$	O_{rc}	O_{x_r}
	O_{y_1}	O_{y_2}	$\dots$	O_{y_c}	n

- H_0 : Proměnné jsou nezávislé.

Očekávaná (expected) četnost (e_{ij})

$$e_{ij} = \frac{O_{x_i} O_{y_j}}{n}$$

Chi-kvadrát (χ^2) test

Porovnává **pozorované** a **očekávané** četnosti.

$$\chi^2 = \sum \frac{(O - E)^2}{E}$$

Kdy je výsledek významný?

Pokud $p < 0.05$, zamítáme H_0 a tvrdíme, že mezi kategoriemi existuje asociace.

Příklad: Výpočet χ^2 (Chí-kvadrát)

Otázka: Liší se preference jazyka u datových vědců (DS) a analytiků (DA)? ($N = 100$)

1. Pozorované četnosti (O)

Pozice	Python	R	Sum
DS	40	10	50
DA	20	30	50
Sum	60	40	100

1. Očekávané četnosti (E)

Pozice	Python	R	Sum
DS	30	20	50
DA	30	20	50
Sum	60	40	100

např. $E_{DS,Py} = \frac{50 \times 60}{100} = 30$

Statistický text

$$\chi^2 = \frac{(40-30)^2}{30} + \frac{(10-20)^2}{20} + \dots$$

$$\chi^2 = 3.33 + 5.0 + 3.33 + 5.0 = \mathbf{16.66}$$

4. Interpretace

- Stupně volnosti $df = (2 - 1)(2 - 1) = 1$
- Kritická hodnota (5%) = **3.84**
- $16.66 > 3.84 \implies$ **Zamítáme H_0**

Existuje statisticky významný vztah.

`w-eda-chi2.ipynb`

Vizualizace kontingenční tabulky

100% Stacked Bar Chart

- Nejlepší pro porovnání **proporcí**.
- Normalizace sloupce na 1 (100 %).
- Umožňuje vizuálně porovnat relativní zastoupení kategorií napříč skupinami.

(Např. Python vs. R u různých pozic)

Skládaný sloupcový graf (varianty)

- Standardní skládaný sloupcový graf.
- Skupinový skládaný sloupcový graf.
- **100% skládaný sloupcová graf.**

Heatmap (Teplotní mapa)

- Vhodná pro **velké tabulky** ($n \times m$).
- Barva reprezentuje buď:
 1. Absolutní četnost.
 2. **Rezidua** (odchylku $O - E$).
- Rychle odhalí nečekané vazby v datech (horká místa).
- Vizualizace reziduí nám řekne nejen ŽE existuje vztah, ale KDE je nejsilnější.

`w-eda-contingency.ipynb`

Analýza více proměnných

Multivariační analýza: Pairplot (Scatter Matrix)

- V praxi nás nezajímají jen dvojice, ale interakce mezi všemi proměnnými v datasetu.


Co je to Pairplot?

Mřížka grafů ($n \times n$), kde každá proměnná vystupuje na obou osách.

- **Diagonála:** Histogramy nebo KDE (hustota) jednotlivých proměnných.
- **Mimo diagonálu:** Bodové grafy zobrazující biviační vztahy.

EDA Strategie

Ideální první krok po importu dat.
Okamžitě odhalí **multikolinearitu** a skryté shluky (Clusters).



Komplexní mapa vztahů v datech

`w-eda-pairplot.ipynb`