Analýza asociací

Analýza informačních zdrojů

Metody strojového učení

Vojtěch Ondryhal

Katedra informatiky a kybernetických operací, UO Brno

2026

(2026.408)

Přehled

1. Asociační pravidla
   - Základní pojmy, definice, pokrytí
   - Podpora, spolehlivost a zdvih
   - Metody a algoritmy
2. Metoda Apriori
   - Nalezení frekventovaných skupin
   - Generování asociačních pravidel
   - Implementace

Přehled

1. Asociační pravidla
   - Základní pojmy, definice, pokrytí
   - Podpora, spolehlivost a zdvih
   - Metody a algoritmy
2. Metoda Apriori

Analýza asociací

Úloha nalezení asociačních pravidel v datovém vzorku.

- Cílem je nalezení asociací mezi položkami (atributy) v datech, resp. současného výskytu datových položek.
- Základní nesupervizovaná úloha data miningu.
- Metoda byla poprvé aplikována na úlohu analýzy nákupního košíku[1], při které se zjišťovalo jak jsou spolu nakupovány jednotlivé druhy zboží.
- Metoda je vhodná jen pro kategoriální proměnné.

[1] Agrawal et al in 1993

Typické úlohy analýzy asociací

- **Analýza nákupního košíku**.
  - Analýza společně nakupovaných položek.

  → Pochopení nakupovacích návyků zákazníků.

  → Zvýšení prodeje lepším rozmístěním produktů na prodejnách.
- **Segmentace zákazníků**.
  - Nalezení společných charakteristik pro skupiny (např. dle věku, geografické lokace).

  → Úprava marketingové kampaně, personalizovaná doporučení pro vybrané skupiny zákazníků.
- **Odhalování podvodného jednání**.
  - Identifikace podvodných transakcí nebo pojišťovacích podvodů.

  → Opakované nákupy od stejného obchodníka v krátkém období.

  → Odhalení organizované skupiny v dané oblasti. Pravidlo: Pokud je poškozené vozidlo značky A a nehoda se stala v oblasti B, pak je pojistná událost nahlášena v pátek odpoledne.

Typické úlohy analýzy asociací

- **Analýza sociálních sítí**.
  - Nacházení vzorů chování v těchto sítích.
  - Uživatel píšící zprávy k danému tématu bude pravděpodobně psát i jiným tématům.

  → Identifikace skupin a komunit na sítích.
- **Doporučovací systémy**.
  - Analýza asociací může doporučit položky, o které by mohl mít zákazníka zájem, dle aktuálních nákupů či historie prohlížení.

  → Např. streamovací služba doporučí dalšího umělce nebo skladbu na základě historie poslechu.

Definice úlohy

Nechť je dána množina

- všech položek $I = \{i_1, i_2, \ldots\ i_m\}$,
- transakcí $T = \{t_1, t_2, \ldots\ t_n\}$, přičemž platí, že $t_i \subseteq I$.

Asociační pravidlo

je implikace ve tvaru:

$$X \rightarrow Y, \text{ kde } X \subset I,\ Y \subset I \text{ a } X \cap Y = \emptyset.$$

X (předpoklad, *antecedent*) a Y (závěr, *konsekvent*) jsou skupinami položek (*itemsets*).

- Jestliže skupina položek obsahuje k prvků, pak hovoříme o skupině položek velikosti k (k-*itemset*).

Příklad

Analýza prodaného zboží

Analýza, jak se spolu jednotlivé položky v obchodě prodávají.

- I - množina všech položek zboží v obchodě.
- Transakce je pak jeden nákup (nákupní košík) zákazníka.

Příkladem transakce v obchodě s elektronikou může být:

- $\{myš, baterie, podložka\}$,
- Zákazník koupil zároveň myš, baterie a podložku.

Příkladem asociačního pravidla pak:

- $\{myš, baterie\} \rightarrow \{podložka\}$, kde $\{myš, baterie\}$ je X a $\{podložka\}$ je Y.
- Složené závorky se často neuvádějí, takže by pak asociační pravidlo vypadalo následovně:
- $myš, baterie \rightarrow podložka$.

Pokrytí

X **pokrývá** t_i:

- jestliže $X \subset t_i$, tj. transakce t_i obsahuje skupinu položek X.
- $X.count$ - počet transakcí v T, které obsahují X (pokrývají).

Síla (významnost) pravidla se měří dvěma primárními veličinami:

- **podporou** (*support*).
- **spolehlivostí** (*confidence*).

Další veličiny mohou sledovat korelaci mezi skutečným a očekávaným výskytem skupin, např. **zvýšení** (*lift*).

Podpora

Podpora pravidla $X \rightarrow Y$

- je procento transakcí v T, které obsahují X i Y, tj. $X \cup Y$.
- Lze pohlížet jako na odhad pravděpodobnosti $Pr(X \cup Y)$.
- Podpora určuje, jak často je pravidlo aplikováno v množině T. Je-li n počet transakcí v T.

$$support = Pr(X \cup Y) = \frac{(X \cup Y).count}{n} \quad (1)$$

- Jestliže je podpora příliš nízká, znamená to, že se pravidlo vyskytlo zřejmě náhodně a nemá další význam jej zpracovávat. Pravidlo pokrývá příliš málo případů.

Spolehlivost

Spolehlivost pravidla $X \rightarrow Y$

- je procento transakcí v T, které když obsahují X, pak obsahují i Y.
- Lze jej chápat jako odhad podmíněné pravděpodobnosti $Pr(Y|X)$.

$$confidence = Pr(Y|X) = \frac{(X \cup Y).count}{X.count} \tag{2}$$

- Spolehlivost vyjadřuje míru předvídatelnosti pravidla.
- Jestliže je tato míra nízká, pak se na pravidlo nelze spolehnout, Y nelze z X odvodit.

Definice úlohy analýzy asociací

Máme k dispozici množinu transakcí T

Cíl dolování z pravidel

Nalezení **všech** pravidel,

- které mají podporu a spolehlivost vyšší nebo rovnu,
- než uživatelem definovaná minimální hodnota podpory a spolehlivosti.

Příklad

Množina I jsou všechny druhy zboží prodávané v prodejně.
Množina T jsou transakce (nákupy) v prodejně.

t_1: ryba, pečivo, sýr
t_2: ryba, mléko
t_3: mléko, noviny
t_4: ryba, pečivo, mléko
t_5: ryba, pečivo, zelenina, mléko, sýr
t_6: pečivo, zelenina, sýr
t_7: pečivo, sýr, zelenina
t_8: pečivo, mléko, zelenina, ryba

Definujme minimální požadované hodnoty:

- podporu $minsup = 30\%$, spolehlivost $minconf = 70\%$.

Splňuje následující pravidlo podmínky?

- $pecivo, zelenina \rightarrow syr$

Příklad

Množina I jsou všechny druhy zboží prodávané v prodejně.
Množina T jsou transakce (nákupy) v prodejně.

t_1: ryba, pečivo, sýr
t_2: ryba, mléko
t_3: mléko, noviny
t_4: ryba, pečivo, mléko
t_5: ryba, pečivo, zelenina, mléko, sýr
t_6: pečivo, zelenina, sýr
t_7: pečivo, sýr, zelenina
t_8: pečivo, mléko, zelenina, ryba

Definujme minimální požadované hodnoty:

- podporu $minsup = 30\%$, spolehlivost $minconf = 70\%$.

Splňuje následující pravidlo podmínky?

- $pecivo, zelenina \rightarrow syr$
- $sup = 3/8$, $conf = 3/4$

Sleduje vztah nezávislosti skupin X a Y v asociačním pravidle.

- Hodnotí, kolikrát je pravděpodobnější, že se položky X a Y zakoupí společně, než kdyby byly kupovány nezávisle:

$$\text{lift}(X \to Y) = \frac{P(X \cup Y)}{P(X) \cdot P(Y)} = \frac{P(Y|X)}{P(Y)} = \frac{\text{conf}(X \to Y)}{\sup(Y)} \tag{3}$$

- $\text{lift} = 1$: X a Y jsou nezávislé (Y není ovlivněno výskytem X).
- $\text{lift} > 1$: pozitivní asociace (výskyt X zvyšuje pravděpodobnost výskytu Y).
- $\text{lift} < 1$: negativní asociace (výskyt X snižuje pravděpodobnost výskytu Y).
- Příklad: Je-li zdvih 1,5, pak je 1,5x pravděpodobnější, že zákazník koupí výrobek A, jestliže si koupil výrok B.

Lift je symetrický ($\text{lift}(X \to Y) = \text{lift}(Y \to X)$), neodráží směrovost implikace.

Leverage (Páka)

Rozdíl mezi pozorovanou společnou četností a očekávanou četností při nezávislosti:

$$\text{leverage}(X \to Y) = \sup(X \cup Y) - \sup(X) \cdot \sup(Y) \tag{4}$$

leverage $= 0$: nezávislost; rozsah hodnot: $[-0{,}25; 0{,}25]$.

Absolutní rozdíl vs. poměr (porovnání s Liftem):

- Zatímco lift počítá poměr ($\frac{P(X \cup Y)}{P(X)P(Y)}$), leverage počítá jejich rozdíl.
- Díky tomu upřednostňuje pravidla s vyšší celkovou podporou (četnost v datech), zatímco lift může nabývat vysokých hodnot i u velmi vzácných položek.

Conviction (Přesvědčení)

Měří závislost pravidla na nesprávném předpokladu (míra chybovosti):

$$\text{conviction}(X \to Y) = \frac{1 - \sup(Y)}{1 - \text{conf}(X \to Y)} \tag{5}$$

Je **směrové**: $\text{conv}(X \to Y) \neq \text{conv}(Y \to X)$, $1 \to$ nezávislost, $\infty \to 100\%$ spolehlivost pravidla.

Míra chybovosti / nezávislosti: Conviction porovnává četnost, se kterou by Y nenastalo při nezávislosti X a Y, s četností, se kterou pravidlo ve skutečnosti chybuje (tj. X nastane, ale Y nenastane).

Algoritmy

Metody pro asociační pravidla vracejí stejný výsledek, tj. úplnou množinu pravidel na základě definované podpory a spolehlivosti.

- **Apriori**
  - Postupně hledá frekventované skupiny položek.
  - Každá podmnožina frekventované skupiny je frekventovaná.
  - Iterativně prohledává databázi - pomalé u velkých dat.
- **FP-Growth** (Frequent Pattern Growth)
  - Efektivnější alternativa k Apriori, která komprimuje databázi do stromové struktury (FP-strom).
  - Dvojprůchodový algoritmus - výrazné zrychlení.
- **Eclat**
  - Vertikální reprezentace dat – pro každou položku si pamatuje seznam transakcí, kde se vyskytuje.
  - Průniky těchto seznamů - rychlé pro menší datové sady.

Přehled

1. Asociační pravidla

2. Metoda Apriori
   - Nalezení frekventovaných skupin
   - Generování asociačních pravidel
   - Implementace

Apriori

Nejznámější algoritmus pro dolování pravidel. Tento algoritmus se skládá ze dvou základních kroků:

1. Nalezení všech frekventovaných skupin prvků (*itemsets*), což jsou skupiny, které mají vyšší podporu než minimální požadovanou.
2. Nalezení všech spolehlivých asociačních pravidel, tj. pravidel z frekventovaných skupin prvků se spolehlivostí vyšší než minimální.

Nalezení frekventovaných skupin

Věta Apriori frekventované množiny

- Věta sestupné uzávěry (*downward closure lemma*).

Věta se vyskytuje ve dvou variantách:

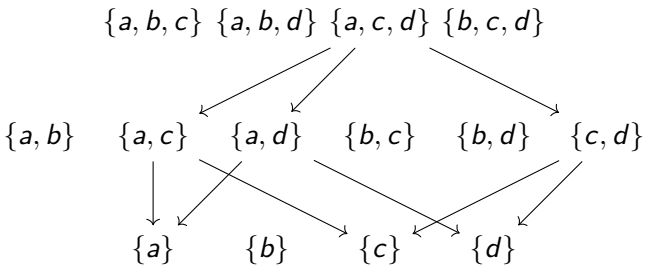
Věta apriori

Pokud je skupina položek frekventovaná (má minimální podporu), pak všechny její podmnožiny jsou také frekventované.

Obráceně (významnější)

Pokud jakákoliv podmnožina skupiny položek není frekventovaná (nemá minimální podporu), pak skupina nemůže být frekventovaná.

Ilustrace věty Apriori



Nechť je $\{a, c, d\}$ jedinou frekventovanou skupinou velikosti 3. Na základě věty Apriori jsou frekventovanými skupinami velikosti 2 a 1 ty, které jsou podmnožinou této frekventované skupiny.

Algoritmus je **iterativní**.

- V prvním kroku nalezneme frekventované skupiny velikosti 1.
- V další iteraci frekventované skupiny velikosti 2, atd.
- Tento přístup umožní zastavit algoritmus na požadované úrovni velikosti skupin.
- Skupiny větších velikostí obvykle neposkytují významné informace.

Lexikografické uspořádání

- Předpokládejme, že prvky množiny I jsou lexikograficky (podle abecedy) uspořádány.
- Všechny skupiny budou takto v krocích algoritmu uspořádány.
- Lexikografické uspořádání = slovníkové uspořádání.

Algoritmus nalezení frekventovaných skupin

Algorithm 1 Apriori(T)

1: $C_1 \leftarrow init_pruchod(T)$ ▷ Získáme kandidáty velikosti 1.
2: $F_1 \leftarrow \{c | c \in C_1, support(c) > minsup\}$
3: **for** $(k = 2; F_{k-1} \neq \emptyset; k{+}{+})$ **do**
4: $\quad C_k \leftarrow seznam_kandidatu(F_{k-1})$
5: $\quad F_k \leftarrow \{c | c \in C_k, support(c) > minsup\}$
6: **return** $F \leftarrow \bigcup_k F_k$

- Najdeme kandidáty velikosti 1 (řádek 1) v transakční DB.
  - Počítají se počty výskytů v jednotlivých transakcích.
  - Kandidáti splňující minimální podporu (řádek 2), jsou zařazeni do frekventovaných skupin velikosti 1.
- Iterativně (řádek 3) nalezneme kandidáty vyšších velikostí.
  - Funkce `seznam_kandidatu()` (popsáno samostatně)
  - Znovu projdeme transakční DB a ověřujeme minimální podporu
  - Je-li minimální podpora → frekventovaná skupina velikosti k.

Algoritmus nalezení frekventovaných skupin

Funkce: Seznam kandidátů

Algorithm 2 seznam_kandidatu(F_{k-1})

1: $C_k \leftarrow \emptyset$ ▷ Na začátku nemáme žádné kandidáty
2: **for all** $\{f, g | f, g \in F_{k-1}, f_i = g_i, i = (1, \ldots, k-2), f_{k-1} < g_{k-1}\}$ **do**
3: $\quad c \leftarrow \{f_1, f_2, \ldots, f_{k-1}, g_{k-1}\}$
4: $\quad$ **if** $\forall s \in subset_{k-1}(c) : s \in F_{k-1}$ **then**
5: $\quad\quad C_k \leftarrow C_k \cup c$
6: **return** C_k

- Vrací kandidáty dle frekventovaných skupin nižší úrovně.
  - V prvním kroku nalezneme všechny dvojice frekventovaných skupin, které se liší v posledním prvku (řádek 2).
  - Skupiny zkombinujeme. Vznikne skupina c o jednu větší. Ke stejným prvkům doplníme oba poslední prvky (řádek 3).
  - Test na frekventovanou skupinu. Všechny kombinace prvků musí být také frekventované skupiny (řádek 4).
  - Je-li podmínka splněna zahrneme do seznamu kandidátů (řádek 5). Stále zachováváme lexikografické uspořádání.

Zadání

Mějme následující množinu frekventovaných skupin velikosti 3:

$$F_3 = \{\{a, b, c\}, \{a, b, d\}, \{a, c, d\}, \{a, c, e\}, \{b, c, d\}\}.$$

Najděte všechny kandidáty frekventovaných skupin velikosti 4.

Procházením zjistíme, že existují dva potenciální kandidáti. Kandidáti vzniknou kombinací skupin se stejným prvním a druhým prvkem. Kombinujeme $\{a, b, c\}$ s $\{a, b, d\}$, $\{a, c, d\}$ s $\{a, c, e\}$.

$$C_4' = \{\{a, b, c, d\}, \{a, c, d, e\}\}.$$

Druhý kandidát není relevantní, např. $\{a, d, e\}$ není frekventovaná skupina velikosti 3, a proto jej odstraníme z kandidátů.

$$C_4 = \{\{a, b, c, d\}\}.$$

Algoritmus nalezení frekventovaných skupin

Komplexní příklad

Zadání

Mějme následující transakční databázi T. Požadujeme minimální podporu 50%. Nalezněte pomocí algoritmu Apriori všechny frekventované skupiny všech velikostí.

$$T = \{\{a, c, d\}, \{b, c, e\}, \{a, b, c, e\}, \{b, e\}\}$$

Postupujeme v následujících krocích:

Zadání

Mějme následující transakční databázi T. Požadujeme minimální podporu 50%. Nalezněte pomocí algoritmu Apriori všechny frekventované skupiny všech velikostí.

$$T = \{\{a, c, d\}, \{b, c, e\}, \{a, b, c, e\}, \{b, e\}\}$$

Postupujeme v následujících krocích:

1. Nalezneme všechny kandidáty velikosti 1.
   $C_1 = \{\{a\}, \{b\}, \{c\}, \{d\}, \{e\}\}$
   Spočteme jejich absolutní podporu.
   $sup(C_1) = \{\{a\} : 2, \{b\} : 3, \{c\} : 3, \{d\} : 1, \{e\} : 3\}$
   Minimální požadovaná podpora je 50%. Transakcí je $n = 4$. Frekventované skupiny velikosti 1 (vypadl prvek $\{d\}$):
   $F_1 = \{\{a\}, \{b\}, \{c\}, \{e\}\}$

2. Vytvoříme kandidáty velikosti 2 kombinací frekventovaných skupin velikosti 1 (lexikografické uspořádání).
   $C_2 = \{\{a, b\}, \{a, c\}, \{a, e\}, \{b, c\}\, \{b, e\}, \{c, e\}\}$
   Spočteme podporu.
   $\sup(C_2) = \{\{a, b\} : 1, \{a, c\} : 2, \{a, e\} : 1, \{b, c\} : 2\, \{b, e\} : 3, \{c, e\} : 2\}$
   Filtrujeme frekventované skupiny s minimální podporou.
   $F_2 = \{\{a, c\}, \{b, c\}\, \{b, e\}, \{c, e\}\}$

2. Vytvoříme kandidáty velikosti 2 kombinací frekventovaných skupin velikosti 1 (lexikografické uspořádání).
   $C_2 = \{\{a, b\}, \{a, c\}, \{a, e\}, \{b, c\}\, \{b, e\}, \{c, e\}\}$
   Spočteme podporu.
   $\sup(C_2) = \{\{a, b\} : 1, \{a, c\} : 2, \{a, e\} : 1, \{b, c\} : 2\, \{b, e\} : 3, \{c, e\} : 2\}$
   Filtrujeme frekventované skupiny s minimální podporou.
   $F_2 = \{\{a, c\}, \{b, c\}\, \{b, e\}, \{c, e\}\}$
3. Vytvoříme kandidáty velikosti 3. Na základě algoritmu musíme vzít po dvojicích skupiny, které mají stejný první prvek. V našem příkladě se jedná jen o jednu dvojici $\{b, c\}$ a $\{b, e\}$, kde b je společným prvním prvkem. Takže potencionálním kandidátem je:
   $C'_3 = \{\{b, c, e\}\}$

3. (pokr.) Musíme rozhodnout, zda se jedná o relevantního kandidáta. Všechny uspořádané podmnožiny velikosti $k-1$ (zde velikosti 2) musí být frekventovanými skupinami.
   $S_{C'_{3,1}} = \{\{b,c\},\{b,e\}\{c,e\}\}$
   Porovnámím se seznamem frekventovaných skupin F_2 zjistíme, že tomu tak je, tudíž:
   $C_3 = \{\{b,c,e\}\}$
   Zjistíme podporu:
   $sup(C_3) = \{\{b,c,e\} : 2\}$ Kandidát splnil požadavek minimální podpory. Máme tedy:
   $F_3 = \{\{b,c,e\}\}$

3. (pokr.) Musíme rozhodnout, zda se jedná o relevantního kandidáta. Všechny uspořádané podmnožiny velikosti $k-1$ (zde velikosti 2) musí být frekventovanými skupinami.
   $S_{C'_{3,1}} = \{\{b,c\},\{b,e\}\{c,e\}\}$
   Porovnámím se seznamem frekventovaných skupin F_2 zjistíme, že tomu tak je, tudíž:
   $C_3 = \{\{b,c,e\}\}$
   Zjistíme podporu:
   $sup(C_3) = \{\{b,c,e\} : 2\}$ Kandidát splnil požadavek minimální podpory. Máme tedy:
   $F_3 = \{\{b,c,e\}\}$
4. Výsledkem je následující množina frekventovaných skupin splňující minimální podporu 0,5:
   $F = \{\{a\},\{b\},\{c\},\{e\},\{a,c\},\{b,c\}\{b,e\},\{c,e\},\{b,c,e\}\}$

Generování asociačních pravidel

Druhý krok Apriori algoritmu.

Pravidla generujeme pro každou frekventovanou skupinu f.

- $k \geq 2$ - vynecháme frekventované skupiny velikosti 1.
- Vytvoříme všechny neprázdné podmnožiny h skupiny f.
- Pro každou podmnožinu h vytvoříme pravidlo ve tvaru:

$$(f - h) \rightarrow h \tag{6}$$

Musí být splněna podmínka spolehlivosti:

$$confidence = \frac{f.count}{(f - h).count} \geq minconf \tag{7}$$

- Při výpočtu $f.count$ a $(f - h).count$ máme již k dispozici.
- Jedná se absolutní podporu frekventovaných skupin nalezených při generování všech frekventovaných skupin
- Oba f i $(f - h)$ jsou frekventované skupiny.

Zadání

Nalezněte všechna asociační pravidla se spolehlivostí větší než 80% pro frekventovanou skupinu $f = \{b, c, e\}$ z předchozího příkladu.

- Vytvoříme všechny neprázdné podmnožiny skupiny f:
  $H = \{\{b, c\}, \{b, e\}\{c, e\}, \{b\}, \{c\}, \{e\}\}$
- Pro každou podmnožinu H_m vytvoříme odpovídající pravidlo. Pro první podmnožinu máme:
  $r_1 : \{e\} \rightarrow \{b, c\}$
  Spočítáme spolehlivost pravidla:
  - Víme že $supa(\{e\}) = 3$ a $supa(\{b, c, e\}) = 2$,

  $\rightarrow$ tedy conf(r1) $= 2/3$.

Generování asociačních pravidel

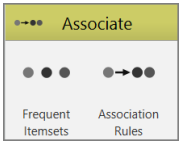
Příklad.

- Vytvoříme ostatní pravidla a doplníme spolehlivost:
  $r_2 : \{c\} \rightarrow \{b, e\}$ [conf=2/3]
  $r_3 : \{b\} \rightarrow \{c, e\}$ [conf=2/3]
  $r_4 : \{c, e\} \rightarrow \{b\}$ [conf=2/2]
  $r_5 : \{b, e\} \rightarrow \{c\}$ [conf=2/3]
  $r_6 : \{b, c\} \rightarrow \{e\}$ [conf=2/2]
- Zadání odpovídají pravidla r_4 a r_6. Obě pravidla mají podporu 50% a spolehlivost 100%:
  $r_4 : \{c, e\} \rightarrow \{b\}$ [sup=0,5; conf=1]
  $r_6 : \{b, c\} \rightarrow \{e\}$ [sup=0,5; conf=1]

Máme již všechna pravidla?

Asociační pravidla nejsou obsažena v základní instalaci.

- Samostatný doplněk, který si musíme doinstalovat.
- V seznamu doplňků `Options` → `Add-ons` vybereme doplněk `Associate`.
- Po instalaci doplňku jsou v nové záložce *Associate* v postranní liště dostupné dva nové uzly.



Frequent Itemsets	Nalezne a zobrazí frekventované skupiny.
Association Rules	Indukuje a zobrazí asociační pravidla z dat.

Implementace

Python

Knihovna `apyori` (jednoduchá)

- Vyžaduje List of Lists jako přímý vstup.

```
from apyori import apriori
import pandas as pd
# Transakční data ve formátu List of Lists (vstup pro apyori)
transactions = [ ['mléko', 'chléb', 'vejce'],
    ['káva', 'máslo'],
    ['mléko', 'máslo'] ]

pravidla_gen = apriori(
    transactions,
    min_support=0.3, min_confidence=0.2,
    min_lift=1.0, min_length=2 )

# Výsledek je generátor, převedeme na seznam
results = list(pravidla_gen)
```

Implementace

Python

Knihovna `mlxtend` (preferovaná s Pandas)

- Vyžaduje One-Hot Encoding, tj. DataFrame s True/False hodnotami.

```
from mlxtend.preprocessing import TransactionEncoder
te = TransactionEncoder()
te_ary = te.fit(transactions).transform(transactions)
df_ohe = pd.DataFrame(te_ary, columns=te.columns_)
# df_ohe je nyní One-Hot Encoded DataFrame
```

```
from mlxtend.frequent_patterns import apriori, association_rules
# Najdi frekventované (časté) sady položek
frequent_itemsets = apriori(df_ohe, min_support=0.3, use_colnames=True)
# Generuj asociační pravidla z častých sad
rules_df = association_rules(frequent_itemsets, metric="lift",
↪  min_threshold=1.0)
```

Další knihovny: `efficient_apriori`, `PyCaret` (3.11).

Jak zjistit množinu všech položek (I)

S využitím množin (`set`).

```python
# Předpokládaný vstup (transakce)
transactions = [ ['mléko', 'chléb', 'vejce'],
['káva', 'máslo', 'vejce'],
['mléko', 'máslo'] ]

# 1. Zploštění seznamu seznamů do jednoho seznamu
all_items = [item for transaction in transactions for item in
↪  transaction]
# 2. Použití set() pro získání unikátních položek
unique_items_set = set(all_items)
# 3. Převod zpět na seznam, pokud je to potřeba
unique_items_list = list(unique_items_set)

print(unique_items_list)
# Výstup: ['vejce', 'mléko', 'chléb', 'káva', 'máslo'] (pořadí se může
↪  lišit)
```

Jak zjistit množinu všech položek (I)

Pomocí knihovny `mlxtend`.

```
import pandas as pd
from mlxtend.preprocessing import TransactionEncoder

transactions = [
['mléko', 'chléb', 'vejce'],
['káva', 'máslo', 'vejce'],
['mléko', 'máslo'] ]

te = TransactionEncoder()
te.fit(transactions) # Naučí se všechny unikátní položky

# Unikátní položky jsou uloženy v atributu .columns_
unique_items_mlxtend = te.columns_

print(unique_items_mlxtend)
# Výstup: ['chléb', 'káva', 'máslo', 'mléko', 'vejce']
```

Co jsme prošli

1. Asociační pravidla
   - Základní pojmy, definice, pokrytí
   - Podpora, spolehlivost a zdvih
   - Metody a algoritmy

2. Metoda Apriori
   - Nalezení frekventovaných skupin
   - Generování asociačních pravidel
   - Implementace