Analýza shluků

Analýza informačních zdrojů

Metody strojového učení

Vojtěch Ondryhal

Katedra informatiky a kybernetických operací, UO Brno

2026

(2026.262)

Přehled

1. Základní pojmy a dělení metod
   - Shluk. Seskupování
   - Dělení metod
2. Vybrané metody analýzu shluků
   - Algoritmus k-Means
   - Aglomerativní seskupování
   - Algoritmus DBSCAN
   - Mřížky a podprostory
3. Měření kvality seskupování
   - Analýza siluety
   - Metoda elbow - loket

Supervizované učení vs. Analýza shluků

Supervizované učení

Při supervizovaném učení se hledají vzory v datech na základě navázání atributů na cílový atribut (třídu). Nalezené vzory slouží ke klasifikaci nebo predikci cílové proměnné u nových datových instancí.

Analýza shluků

Jiným typem úlohy je nalezení podobností mezi instancemi datové množiny. Data pak seskupujeme do skupin na základě této podobnosti. Seskupování patří mezi nesupervizované učení, resp. učení bez učitele, protože dopředu neznáme skupiny, dokonce ani jejich počet.

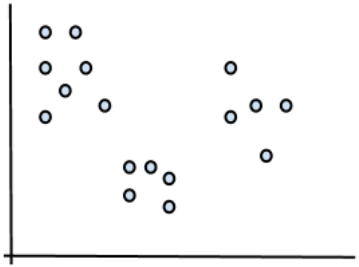
Pojmy a definice

- **Seskupování** (*clustering*) je proces organizování objektů do skupin, ve kterých jsou si její členové „nějak“ podobní.
- **Skupina** (*cluster*) je kolekce datových objektů, které jsou si navzájem podobné a zároveň odlišné od objektů jiných skupin.
- Často se při seskupování používá pojem **objekt**, někdy též **datový bod**, který lze chápat jako bod v n-dimenzionálním prostoru, kde n je počet atributů.
- Můžeme se také setkat s pojmem **segmentace**. Jedná se nejčastěji o seskupování v oblastech marketingového výzkumu. Vytvářejí se např. segmenty zákazníků, které je možno oslovit v rámci kampaně.
- Shlukovou analýzu lze využít i pro detekci **hraničních případů** (*outliers*), což jsou ty objekty které jsou "příliš"vzdáleny od ostatních shluků.

Vizualizace

Vizualizace je snadná jen pro $n = 2$ a $n = 3$, pro prostory vyšších dimenzí je v podstatě nemožná.

- Na obrázku máme ukázku přirozených skupin pro dvoudimenzionální prostor (dva atributy). V reálných aplikacích takto snadno skupiny obvykle rozlišit nejde.
- K vyhledání skupin je potřeba sofistikované algoritmy.



Dělení metod

Dělení shlukovacích metod není snadné, protože mnoho metod můžeme zařadit do více kategorií, přesto můžeme rozlišit následující základní typy metod:

- **Rozdělovací** metody (*partitioning methods*).
- **Hierarchické** metody (*hierarchical methods*).
- Metody založené na **hustotě** (*density-based methods*).
- Metody založené na **odhadu modelu** (*model-based methods)*.
- **Mřížkové** metody (*grid-based methods*).

Rozdělovací metody

Metody dělí datové body do **skupin** (*partitions*). Každá skupina představuje shluk v datech.

- Metody obvykle iterativně přerozdělují objekty do skupin, přičemž platí, že každá skupina musí obsahovat aspoň jeden objekt a každý objekt je v právě jedné ze skupin.
- V případě, že nebude dodržena druhá podmínka, dostáváme se do oblasti **fuzzy** shlukovacích metod.

Pro odlišení skupin objektů od ostatních skupin bude zapotřebí podobnostní funkce, která určí jak jsou si dva objekty podobné.

- Jako míru podobnosti používáme vzdálenostní funkci, která měří vzdálenost dvou datových bodů.

- Pro dosažení globálního optima by byly metody v této kategorii výpočetně náročné.
- Používají oblíbené heurististiké metody, kde shluk je reprezentován průměrem objektů ve shluku (**k-means**), popř. jedním z objektů blízko středu (k-medoids).
- Metody jsou rychlé a fungují dobře v případě, že lze v datech najít sférické shluky a datový vzorek není rozsáhlý.
- Metody nejsou vhodné pro nalezení shluků neobvyklých tvarů.

Hierarchické metody

Hierarchické seskupování je založeno na **hierarchické dekompozici** datového vzorku, kdy kromě skupin vidíme i hierarchickou závislost mezi skupinami. Metody dále dělíme na

- aglomerativní (agglomerative, bottom-up),
- dělící (divisive, top-down).

Aglomerativní metody předpokládají, že každý objekt je na začátku samostatných shlukem a postupně vznikají shluky větší, dokud nejsou všechny body v jedné skupině.

U **dělících** je to naopak, začíná se s jednou skupinou, která se postupně dělí, dokud nejsou všechny body samostatně, nebo není splněna podmínka ukončení. Problémem

těchto metod je, že jakmile je v dané iteraci provedeno dělení, nelze, na rozdíl od metod rozdělovacích, bod zařadit v budoucnu do jiné skupiny. Takže **nelze chybné dělení opravit**.
Tato skupina metod je vhodná například pro **dolování z textů** (*text mining*).

Metody založené na hustotě

Základní myšlenka těchto metod spočívá v tom, že shluk roste tak dlouho, dokud hustota v okolí shluku nedosáhne určité minimální hranice.

- Hustotu chápeme jako minimální počet bodů v okolí daného bodu do určité, předem definované vzdálenosti.
- Použitím této metody se může stát, že některé body nebudou součástí žádného shluku. Naleznou se tedy mezní body.
- Kromě jiného je metoda vhodná pro nalezení hraničních případů.
- Mezi zástupce metod založených na hustotě řadíme např. DBSCAN.

Metody založené na odhadu modelu

Metody se snaží odhadnou model, podle kterého by mohly být shluky definovány a pak se snaží data tímto modelem popsat. Může se jednat o následující typy modelů:

- Odhaduje se např. pravděpodobnostní model, podle kterého jsou data ve vzorku distribuována. Např. můžeme předpokládat Gaussovo rozdělení a odhadujeme průměr a odchylku pro každý shluk. Zástupcem je metoda EM (expectation-maximization), vycházející z k-means.
- Další skupinou je tzv. konceptuální shlukování, kdy se snažíme pro každý shluk definovat popisnou charakteristiku skupiny.
- Pro shlukování lze využít i neuronové sítě. Každý shluk je reprezentován **zástupcem** (exemplar), který nemusí být přímo objektem z originálního datového vzorku. Novému datovému vzorku je pak přiřazen odpovídající zástupce. Příkladem metody pracujícím na tomto principu jsou **Kohonenovy samoorganizující se mapy** (SOM, self-organizing maps).

Mřížkové metody

- Metody rozdělí prostor s objekty do konečného počtu buněk, které tvoří mřížku (grid).
- Seskupovací algoritmy pracují výhradně nad touto mřížkou.
- Rychlost metody je závislá více než na počtu objektů na dimenzích mřížky v prostoru.
- Speciální skupinou jsou metody pracující s podprostory, např. CLIQUE.

Osnova

1. Základní pojmy a dělení metod
2. Vybrané metody analýzu shluků
   - Algoritmus k-Means
   - Aglomerativní seskupování
   - Algoritmus DBSCAN
   - Mřížky a podprostory
3. Měření kvality seskupování

Algoritmus k-means

- Jedná se o rozdělovací metodu.
- Je to jeden z nejpoužívanějších algoritmů pro seskupování, který je jednoduchý, snadno se implementuje a přitom je velmi efektivní.
- Jedná se o iterativní algoritmus využívající vzdálenostní funkci, ve kterém uživatel dopředu specifikuje požadovaný počet k **skupin**.

Mějme množinu D datových bodů (objektů) $\{\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_n\}$, kde $\mathbf{x}_i = (x_{i1}, x_{i1}, \ldots, x_{ir})$ je vektor v prostoru $X \subseteq \mathbb{R}^r$ a r je počet atributů. Algoritmu k-means dělí daná data do k skupin. Každá skupina má definovaný **střed** (centroid). **Centroid** obvykle reprezentuje danou skupinu a jedná se o průměr (mean) všech bodů v dané skupině - odtud název k-means.

Popis algoritmu

Algorithm 1 k-means(k, D)

1: Vyber k bodů jako počáteční centroidy
2: **repeat**
3: **for all** $\mathbf{x} \in D$ **do** ▷ Pro každý datový bod
4: Spočti vzdálenosti $dist(\mathbf{x}, \mathbf{m_j})$ ▷ Ke všem centroidům m_j
5: Přiřaď $\mathbf{x}$ k nejbližšímu centroidu
6: Přepočítej centroidy podle přiřazených bodů
7: **until** je splněno kritérium ukončení

- Začíná náhodným výběrem k datových středů - centroidů (ř1).
- Pak pro každý bod spočítá vzdálenost od všech centroidů a bod se přiřadí nejbližšímu z nich (řádky 3-5).
- Po přiřazení všech bodů vznikne pro každý centroid skupina.
- V každé z těchto skupin se přepočítá centroid (řádek 6).

Kritérium ukončení

1. Žádný, nebo jen minimální přesun bodů mezi skupinami.
2. Žádná, nebo jen minimální změna centroidů.
3. Minimální snížení v chybovém součtu čtverců (sum of squared error, SSE).

$$SSE = \sum_{j=1}^{k} \sum_{\mathbf{x} \in C_j} dist(\mathbf{x}, \mathbf{m_j})^2, \tag{1}$$

kde k je počet požadovaných skupin, m_j je centroid j-té skupiny C_j a $dist(\mathbf{x}, \mathbf{m_j})$ je vzdálenost vektoru od jeho centroidu.

Střed a vzdálenot

Algoritmus k-means může být použit pro jakákoliv data, kde lze spočítat střed a vzdálenost. V eukleidovském prostoru je střed skupiny spočítán jako:

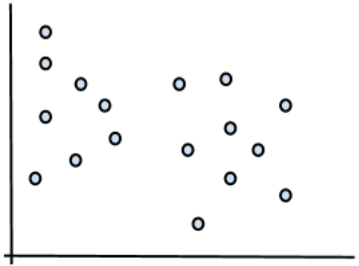
$$\mathbf{m}_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} \mathbf{x}_i, \tag{2}$$

kde $|C_j|$ je počet bodů skupiny C_j. Vzdálenost datového bodu $\mathbf{x}_i$ od středu (centroidu) se spočítá:

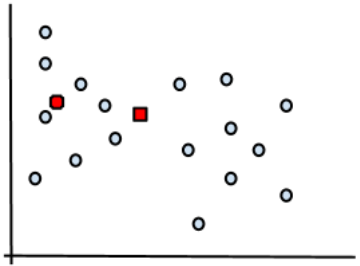
$$dist(\mathbf{x}_i, \mathbf{m}_j) = \|\mathbf{x}_i - \mathbf{m}_j\| \tag{3}$$

$$\|\mathbf{x}_i - \mathbf{m}_j\| = \sqrt{(x_{i1} - m_{j1})^2 + (x_{i2} - m_{j2})^2 + \cdots + (x_{ir} - m_{jr})^2} \tag{4}$$

Příklad

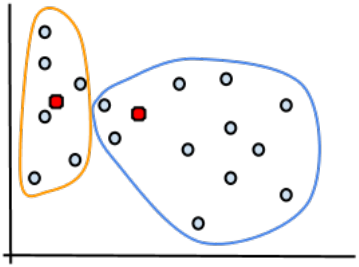


Výchozí datový vzorek

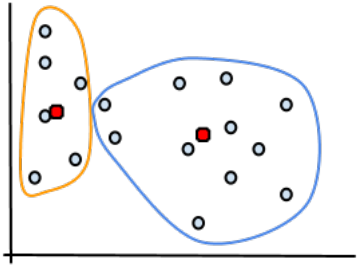


Náhodné středy

Příklad

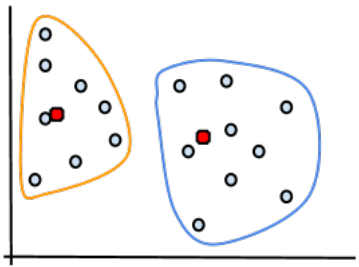


Přiřadíme body do skupin



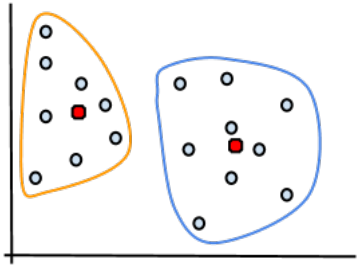
Přepočítáme středy

Příklad



Znovu

přiřadíme body do skupin



Opět

přepočítáme středy

Konec algoritmu

Tady bychom mohli skončit. Body se již nebudou přesunovat.

Poznámky ke k-means

- Algoritmus může vést k tomu, že vznikne **prázdná skupina**, tj. všechny datové body z dané skupiny jsou přiřazeny do jiných skupin. Nejčastěji vybereme jako nový střed nejvzdálenější bod od středu nějvětší skupiny.
- Algoritmus není vhodný pro kategoriální data - obvykle nelze definovat pojem středu. Varianta pro kategoriální proměnné se nazývá **k-modes**. Místo průměrné hodnoty se používá mód (nejčastěji se vyskytující hodnota) datového vzorku. Místo vzdálenosti se používá podobnostní pravidlo podle počtu stejných hodnot ve vektoru.
- Na počátku definujeme počet skupin, obvykle se zkouší více různých počtů skupin.
- Algoritmus je citlivý na extrémní hodnoty.

Reprezentace skupin

Poté, co jsou nalezeny skupiny stojíme před úlohou reprezentace skupin. Obvykle je skupina reprezentována jednou z variant:

- Nejčastěji svým středem (centroidem). Střed určuje pozici skupiny. Můžeme doplnit rádius, popř. odchylkou pro definici rozprostřenosti skupiny v prostoru.
- Použití klasifikačním modelů pro skupinu. Každé skupině přiřadíme návěští třídy a poté použijeme hledáme klasifikační model prodané skupiny (např. pomocí rozhodovacího stromu). Tímto lze pochopit význam jednotlivých skupin.
- Pro kategorizované proměnné používáme nejfrekventovanější kategorii ve skupině pro každý atribut.

Implementace

- Metoda k-means je implementována v knihovně `scikit.learn` pomocí třídy `KMeans`
- `https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html`.
- Orange poskytuje pro k-Means miniaplikaci.

Aglomerativní seskupování

- Seskupováním vznikne posloupnost vnořených skupin.
- Na skupiny se lze dívat optikou stromů, lze je prezentovat pomocí **dendrogramu**.
- Každá skupina obsahuje vnořené skupiny, dokud se nedostane na úroveň jednotlivých datových bodů.
- Kořenem je skupina obsahující všechny datové body.
- Existují dvě základní skupiny metod:
  - **Bottom-up** seskupování - postupně se seskupují nejbližší datové body, dokud nejsou seskupeny všechny body do jedné skupiny.
  - **Top-down** seskupování - postupné dělení bodů do skupin, dokud se nedojde na úroveň jednotlivých bodů.

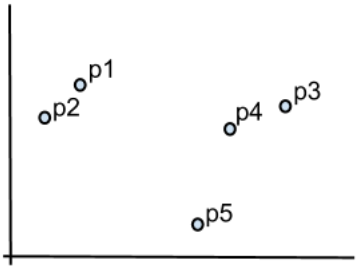
Ukažme si algoritmus bottom-up (algoritmus 2) podrobněji. Tento algoritmus je mnohem používanější než top-down alternativa.

Algorithm 2 bottom_up(k, D)

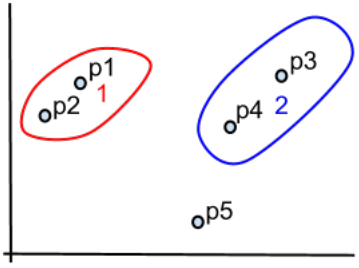
1: Každý datový bod v D se stává skupinou
2: Spočítají se vzdálenosti mezi datovými body $\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_n \in D$
3: **repeat**
4: Najdeme dvě nejbližší skupiny
5: Spojíme tyto skupiny. Vznikla skupina c.
6: Spočítáme vzdálenost skupiny c k ostatním skupinám.
7: **until** Zůstala jedna skupina

Aglomerativní seskupování

Příklad



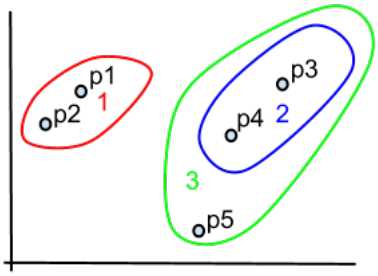
Výchozí datový vzorek



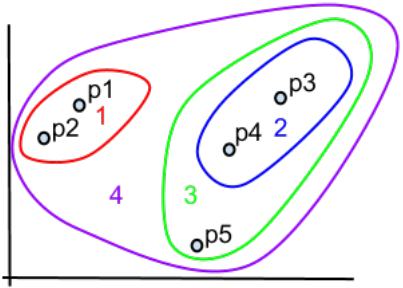
Nalezení skupin 1 a 2.

Aglomerativní seskupování

Příklad



Skupina 3

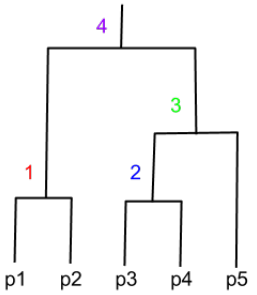


Skupina 4 obsahuje všechny body.

Aglomerativní seskupování

Příklad - dendrogram

- K hierarchickému seskupování lze připojit odpovídající dendrogram.
- U kořene je skupina 4, která se postupně rozpadá až na datové body.
- Vedeme-li horizontální linku od kořene stromu, můžeme vidět rozpady do skupin podle počtu větví, které linka protne.



Na rozdíl od *k-means* - více měr pro vzdálenost mezi shluky.

- Předpokládejme, že máme dva shluky C_i a C_j. Počet bodů v C_i je n_i, v C_j je n_j.
- Vzdálenost dvou libovolných bodů p a q je $|p - q|$.

Minimální vzdálenost (*minimum distance*).

- Nalezne se **nejbližší soused** (*nearest-neighbor*) v dalším shluku, tj. vzdálenost se počítá jako vzdálenost mezi nejbližšími body daných skupin.
- Citlivé na šum v datech.
- Rychlejším speciálním případem je algoritmus *single-linkage*, končí po dosažení dosažena definované hranice.

$$d_{min}(C_i, C_j) = \min_{p \in C_i, q \in C_j} |p - q| \tag{5}$$

Maximální vzdálenost (*maximum distance*), také **nejvzdálenější soused** (*farthest-neigbor*),

- Maximální vzdálenost mezi libovolnými body dvou skupin.
- Sloučí se skupiny s minimálním maximem.
- Citlivé na extrémní hodnoty.
- Speciálním algoritmem hledání vzdálenosti je *complete-link*, který nehledá větší vzdálenost, je-li dosažena definovaná hranice.

$$d_{max}(C_i, C_j) = \max_{p \in C_i, q \in C_j} |p - q| \tag{6}$$

Průměrná vzdálenost (*average distance*). Kompromisní přístup, vzdálenost je průměrnou hodnotou mezi vzdálenostmi dvou libovolných bodů ve skupinách.

$$d_{avg}(C_i, C_j) = \frac{1}{n_i n_j} \sum_{p \in C_i} \sum_{q \in C_j} |p - q| \tag{7}$$

Středová vzdálenost (*mean distance*, *centroid*). Vzdálenost mezi skupinami je vzdáleností mezi centroidy. Je-li m_i průměr shluku C_i a m_j průměr shluku C_j, pak je vzdálenost d_{mean}:

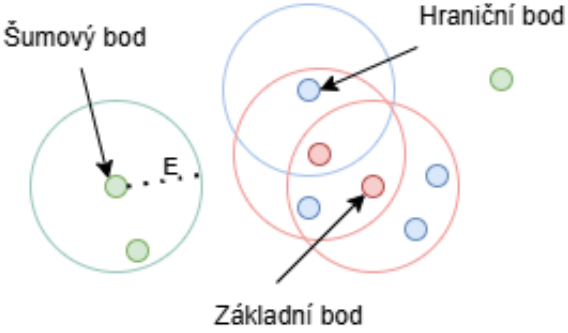
$$d_{mean}(C_i, C_j) = |m_i - m_j| \tag{8}$$

DBSCAN - Shlukování založené na hustotě

DBSCAN (*Density-based Spacial Clustering of Application with Noise*) je shlukovací metoda založená na hustotě. Hustotou v tomto případě myslíme počet bodů v oblasti o poloměru ε. Definujme:

- **Základní bod** (*core point*) je takový, který v okruhu ε obsahuje definovaný minimální počet bodů.
- **Hraniční bod** (*border point*) je takový, který má v okruhu ε menší počet bodů, ale leží v dosahu základního bodu.
- **Šumový bod** (*noise point*) je každý, který není základní ani hraniční.

DBSCAN



min_points = 3

DBSCAN - Shlukování založené na hustotě

Popis algoritmu

1. Každému bodu přiřadíme jednu ze tří tříd (základní, hraniční, šumový).
2. Pro každý základní bod nebo skupinu propojených základních bodů vytvoříme shluk. Propojené základní body jsou v dosahu poloměru ε.
3. Hraniční body přiřadíme do shluku s odpovídajícím základním bodem.

DBSCAN - Shlukování založené na hustotě

Vlastnosti a výhody

- Hlavní výhodou oproti k-means je, že se nepředpokládá sférický shluk jako v k-means.
- Může se ovšem stát, že některé body nebudou přiřazeny do žádného shluku.
- Takové body chápeme jako šum nebo mimořádné hodnoty (outliers).
- DBSCAN je tedy vhodná metoda pro odstranění šumu v datech.

Mřížkové metody

- Rozdělení datového prostoru na konečný počet buněk (mřížku) a následné provádění shlukovacích operací na této mřížce namísto jednotlivých datových bodů.
- Mřížkové metody shlukování jsou techniky, které se používají v dolování dat (data mining) a strojovém učení pro efektivní shlukování velkých datových souborů.

Základní princip

1. **Vytvoření mřížky**. Datový prostor se rozdělí na buňky, které tvoří mřížku. Buňky jsou často hyper-obdélníky.
2. **Výpočet hustoty**. Pro každou buňku se spočítá její hustota, obvykle na základě počtu datových bodů, které se v ní nacházejí.
3. **Identifikace hustých buněk**. Buňky s hustotou nad určitou prahovou hodnotou (definovanou uživatelem) jsou označeny jako "husté". Tyto buňky pravděpodobně obsahují shluky.
4. **Vytvoření shluků**. Shluky se vytvářejí spojením sousedních hustých buněk.

Klíčové charakteristiky a výhody

- **Efektivita**. Hlavní výhodou je, že výpočetní čas je nezávislý na počtu datových bodů a závisí pouze na počtu buněk v mřížce. To je dělá velmi vhodnými pro práci s velkými datovými soubory (snadná škálovatelnost - *scalability*).
- **Rychlost**. Předzpracování dat do mřížky je rychlé, často probíhá v jednom průchodu daty.
- **Zvládání vysoké dimenze**. Mřížkové metody mohou být efektivní i ve vícerozměrném prostoru, a to díky tomu, že pracují s podprostory.

Výzvy a nevýhody

- **Citlivost na parametry**. Výběr správné velikosti buněk a prahové hodnoty hustoty může být náročný a má velký vliv na výsledky shlukování.
- **Tvorba shluků**. Někdy mohou mít potíže se shluky s proměnlivou hustotou nebo s nejasnými hranicemi mezi shluky.
- **Prokletí dimenzionality** (*curse of dimensionality*. I když jsou lepší než jiné metody, ve velmi vysokodimenzionálních prostorech se hustota stává nesmyslnou, což může mít negativní dopad na výkon.

Princip podprostorového shlukování

Algoritmus nepracuje s celým datovým prostorem najednou. Prohledává datovou sadu v jednotlivých podprostorech. Podprostor je vybrána podmnožina původních dimenzí (atributů).

1. **Hledání hustoty v jednorozměrných podprostorech**.
   - Algoritmus začne s jednodimenzionálními podprostory.
   - Rozdělí každou dimenzi na buňky a identifikuje ty, které mají dostatečnou hustotu (tj. obsahují dostatek datových bodů).
2. **Kombinace a expanze**.
   - Princip podobný Apriori algoritmu (viz. asociační pravidla).
   - Kombinuje husté buňky z nižších dimenzí a vytvoří tak husté buňky ve vyšších dimenzích.
   - Například, pokud jsou husté buňky v dimenzi "věk"a v dimenzi "plat", algoritmus zkoumá, zda existují husté buňky v podprostoru tvořeném oběma dimenzemi ("věk"a "plat").
3. **Identifikace shluků**. Shluky jsou tvořeny spojením hustých, na sebe navazujících buněk v příslušných podprostorech.

Princip podprostorového shlukování

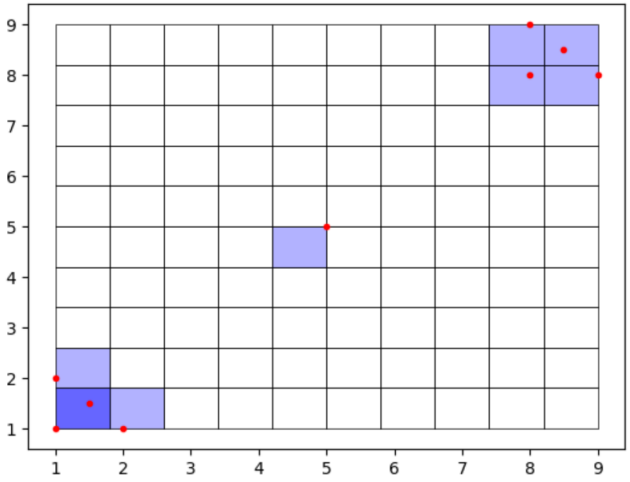
CLIQUE

- Tento přístup umožňuje najít shluky, které existují pouze v určitých kombinacích atributů, zatímco v celém prostoru by se ztratily v "šumu" irelevantních dimenzí.
- Příklad algoritmu podprostorového shlukování - CLIQUE (*Clustering in QUEst*).
  - Dokáže najít podprostory s nejvyšší dimenzionalitou, ve kterých se nachází husté shluky.
  - Efektivním řešením pro analýzu vysokodimenzionálních dat.
- Není součástí `scikit-learn`.
- Nutno použít specializovanou knihovnu `pyclustering`.

```
pip install pyclustering
```

Princip podprostorového shlukování

Vizualizace



Osnova

1. Základní pojmy a dělení metod
2. Vybrané metody analýzu shluků
3. Měření kvality seskupování
   - Analýza siluety
   - Metoda elbow - loket

Měření kvality shlukování

Jelikož shlukovací metody patří do skupiny nesupervizovaných metod, dopředu neznáme optimální počet shluků.

- U některých metod, jako např. **k-means** dokonce dopředu specifikujeme počet shluků na základě znalosti domény nebo odhadem.
- Aglomerativní metody generují velké množství shluků různé velikosti.

Ja zjistíme, že vytvořené shluky jsou optimální?

- Analýza siluety.
- Metoda lokte (*elbow*).

Analýza siluety

Analýzu siluety (*silhouette*, obrys) je možno použít pro libovolnou seskupovací metodu. Výsledek analýzy siluety zobrazíme do grafu, abychom mohli vysledovat, jak jsou vzorky ve shluku seskupeny těsně u sebe.
Algoritmus výpočtu koeficientu siluety pro datový vzorek $x^{(i)}$:

- Spočítáme **soudržnost** $a^{(i)}$ (*cohesion*) jako průměrnou vzdálenost datového vzorku $x^{(i)}$ od ostatních vzorků stejného shluku.
- Spočítáme **oddělení** (separaci) $b^{(i)}$ (*separation*) od nejbližšího shluku jako průměrnou vzdálenost datového vzorku $x^{(i)}$ od ostatních vzorků nejbližšího shluku.

Spočítáme **koeficient siluety** $s^{(i)}$ jako rozdíl mezi soudržností a separací shluku a podělíme větší z obou hodnot.

$$s^{(i)} = \frac{b^{(i)} - a^{(i)}}{\max(a^{(i)}, b^{(i)})} \tag{9}$$

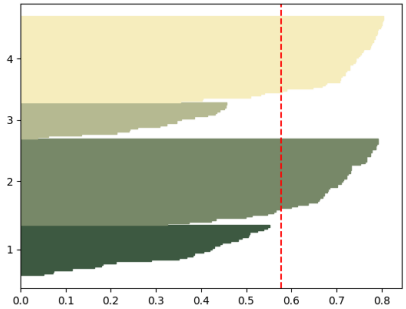
Koeficient siluety je v rozmezí $(-1, 1)$.

- Čím se hodnota $s^{(i)}$ blíží 1, tím je separace datového vzorku kvalitnější, platí $b^{(i)} >> a^{(i)}$.
- Blíží-li se jedné, objekt je zařazen do správného shluku,
- Blíží-li se mínus jedna, jedná se o špatně zařazený objekt.
- Blíží-li se nule, znamená to, že objekt může být zařazen také do jiného shluku, vzorek leží stejně daleko od obou shluků.

Analýza siluety

Graf

- Koeficient siluety pro **shluk** je dán průměrem všech koeficientů v jednom shluku.
- Koeficient siluety pro **metodu** je dán průměrem všech koeficientů (červená linka v grafu).



- Knihovna Scikit Learn poskytuje implementaci koeficientu siluety v balíčku metrik `sklearn.metrics.silhouette_samples` [1].
- Orange poskytuje pro výpočet a zobrazení koeficientu miniaplikaci.



Silhouette Plot

[1] `https://scikit-learn.org/stable/modules/generated/sklearn.metrics.silhouette_samples.html`

Odhad optimálního počtu shluků metodou loket

- Jelikož není dopředu znám počet shluků, který by měl shlukovací algoritmus poskytnout, hledáme způsob jak porovnat výsledky shlukování.
- Použijeme chybovou funkci, která počítá součet čtverců vzdáleností bodů k centroidu ve skupině (SSE, within-cluster sum of squared errors), kterou se snažíme minimalizovat.

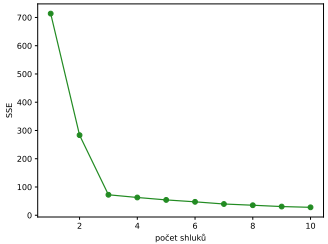
$$SSE = \sum_{j=1}^{k} \sum_{\mathbf{x} \in C_j} dist(\mathbf{x}, \mathbf{m_j})^2, \tag{10}$$

Odhad optimálního počtu shluků metodou loket

Zobrazení do grafu

Budeme-li zvyšovat počet shluků, bude se chyba snižovat (datové vzorky budou blíže centroidům).

- **Metoda loket** (*elbow*) hledá takový počet shluků, kde se chyba rapidně sníží (zlomí se), ale při dalším zvyšování počtu shluků již bude změna chyby minimální.



Na ilustračním obrázku vidíme, že ke zlomu dochází u tří shluků. Budeme tedy považovat tři shluky za optimální řešení.

Přehled

1. Základní pojmy a dělení metod
   - Shluk. Seskupování
   - Dělení metod
2. Vybrané metody analýzu shluků
   - Algoritmus k-Means
   - Aglomerativní seskupování
   - Algoritmus DBSCAN
   - Mřížky a podprostory
3. Měření kvality seskupování
   - Analýza siluety
   - Metoda elbow - loket